

26-1 Modeling Project 프로젝트

IGODA

안재민, 이재원, 조재현, 현승원



INDEX

01. Challenge: 데이터가 사라진 광고 환경

광고 산업의 목표

기존 추천시스템

변화하는 광고 패러다임

02. Approach: 텍스트 임베딩 설계

Upper Bound Model

Baseline Model

Enhanced Model

03. Impact: 성능 개선에서 수익까지

피처 기여도 분석

케이스 스터디

CTR to Revenue

IGONGA



광고 산업의 목표



광고 산업의 목표



CTR (Click-Through Rate, 클릭률)

어떤 콘텐츠(광고, 링크, 썸네일 등)가 사용자에게 노출되었을 때,
그중 비율적으로 얼마나 많은 사람이 실제로 클릭했는가



광고 산업의 목표



CTR (Click-Through Rate, 클릭률)

어떤 콘텐츠(광고, 링크, 썸네일 등)가 사용자에게 노출되었을 때,
그중 비율적으로 얼마나 많은 사람이 실제로 클릭했는가

평균 CTR

1~5%


2025년 기준, 전세계 광고 산업은 1조 달러를 상회하는 규모로
전체 광고 중 디지털 광고가 75% 이상의 비중을 차지

광고 산업의 목표

광고 효과

지면: 어디에 무엇을 광고할 것인가

- 배너/검색/피드
- 광고 포맷
- 브랜드/카테고리



유저: 누구에게 광고를 추천할 것인가

- 인구통계
- 행동 이력
- 관심사


컨텍스트: 어느 시점에 추천할 것인가

- 시간대/요일/시즌
- 디바이스
- 네트워크

기존 추천시스템



User based Collaborative Filtering



특정 사용자와 구매 패턴 및 품목 평가 패턴이 유사한 사용자들을 찾고
이를 기반으로 사용자에게 제품을 추천하는 방법

기존 추천시스템



Cosine Similarity

$$\text{sim}(u, u') = \cos(\theta) = \frac{R_u \cdot R_{u'}}{\|R_u\| \cdot \|R_{u'}\|} = \frac{\sum_{i=1}^n R_{ui} \times R_{u'i}}{\sqrt{\sum_{i=1}^n (R_{ui})^2} \times \sqrt{\sum_{i=1}^n (R_{u'i})^2}}$$

사용자 u와 사용자 u'가 같은 방향을 보고 있는지 평가

Pearson Correlation

$$\text{sim}(u, u') = \frac{\sum_{i=1}^n (R_{ui} - \bar{R}_u)(R_{u'i} - \bar{R}_{u'})}{\sqrt{\sum_{i=1}^n (R_{ui} - \bar{R}_u)^2} \times \sqrt{\sum_{i=1}^n (R_{u'i} - \bar{R}_{u'})^2}}$$

평균적인 경향성에서 얼마나 차이가 있는지 평가

기존 추천시스템

User based Collaborative Filtering

장점

낮은 운영 복잡도

광고 내용을 직접 분석하지 않아도
유저 반응 패턴만으로 개인화 가능함

쿠키 기반 추적 인프라와 높은 호환성

별도의 데이터 수집&변환 없이 쿠키 ID를
그대로 유저 식별자로 활용할 수 있는 환경



단점

Cold Start 대응 어려움

신규 유저 및 제품은 클릭 데이터가
없어 추천이 어려움

데이터 단절 (ID 분산) 문제

디바이스 등이 분리되면 동일인이 여러
ID로 쪼개져 하나의 데이터로 수집 불가

변화하는 광고 패러다임




IGONGA님, 안녕하세요
무엇을 도와드릴까요?

+



변화하는 광고 패러다임




LLM 활용으로 인한 신규 유저 데이터 등장

사례

- OpenAI ChatGPT Search 문서: “질문에 쇼핑 의도가 있으면 제품 옵션을 보여줄 수 있다” 등, 의도 감지를 명시적으로 기능화
- OpenAI Help 문서: 질문에 쇼핑 의도가 보이면 상품 옵션을 보여 주고, 상품 선정 시 사용자 질의와 맥락을 고려함을 발표
- Amazon AI Shopping Guides: LLM이 카탈로그 데이터로 검색 자동완성을 자동 제공

변화하는 광고 패러다임



쿠키 수집 불가 & 개인정보 활용 동의율 하락

사례

- 2017년: Safari, ITP(지능형 추적 방지)를 도입해 3rd-party 추적을 줄이는 방법 추진. 브라우저 단위 추적 제한이 본격화
- 2023년: Chrome, Tracking Protection/Privacy Sandbox 테스트 확대 발표(3rd-party cookies 없는 웹 전환 분기점)
- 2024년: Google, Chrome에서 third-party cookies 전면 폐지 대신 **user choice** 방식으로 방향 전환 발표

과거(3rd party)

- 풍부한 유저 행동 데이터 + 크로스 사이트 추적
- 일정 기간 이상 사용자 로그를 저장해 예측에 활용

현재(1st party 중심, 프라이버시 전환기)

- 3rd-party cookie 단계적 폐지, 1st-party 데이터만 수집 가능
- 유저 기본 데이터 확보도 불확실

미래(LLM/AI 검색 기반)

- AI 검색 및 대화형 검색 확산으로 새로운 사용자 의도 신호 등장

사례

- OpenAI의 ChatGPT Search 문서 : “질문에 쇼핑 의도가 있으면 제품 옵션을 보여줄 수 있다”는 식으로, “의도 감지”를 명시적으로 기능화
- OpenAI Help 문서 : 질문에 쇼핑 의도가 보이면 상품 옵션을 보여주고, 상품 선정 시 사용자 질의와 맥락을 고려한다고 함
- Amazon의 AI Shopping Guides : LLM이 카탈로그 데이터로 검색 자
- 이는 “유저의 장기 행동 로그”가 아니라도 요청 자체(프롬프트/질의)에서 의도를 읽어 피처화할 수 있다는 근거로 추론 가능

변화하는 광고 패러다임

LLM 활용으로 인한 신규 유저 데이터 생성

부족한 유저 데이터로 인해 ID 기반 협업 필터링 성능이 저하될 때
시맨틱 임베딩이 이를 얼마나 보완할 수 있는가

- OpenAI의 ChatGPT Search 문서: "질문에 쇼핑 의도가 있으면 제품 옵션을 보여줄 수 있다"는 식으로, "의도 감지"를 명시적으로 기능화
- OpenAI Help 문서: 질문에 쇼핑 의도가 보이면 상품 옵션을 보여주고, 상품 선정 시 사용자 질의와 맥락을 고려한다고 함
- Amazon의 AI Shopping Guides: LLM이 카탈로그 데이터로 검색 자동완성을 만든다고 밝힘
- 이는 "유저의 장기 행동 로그"가 아니라도 요청 자체(프롬프트/질의)에서 의도를 읽어 피처화할 수 있다는 근거로 추론 가능

전체 실험 구조

실험 목표

- 전체 데이터를 활용한 시퀀스 기반 모델을 구현하고, 해당 성능을 upper bound로 정의
- 데이터가 sparse한 환경에서도 해당 upper bound 성능에 근접하는 것을 목표로 함

Baseline 구축	▶	성능 개선 실험	▶	결과 분석
• Upper Bound Model (Model C) : Full-sequence 기반 모델을 통해 upper bound 성능 정의 • Baseline Model (Model A) : 최근 데이터 수집 제약을 반영해 sparse 환경에서의 baseline 정의		• Enhanced Model (Model B) : baseline 모델에 텍스트 임베딩 기반 사용자 의도 피처를 추가 • Baseline 대비 성능 향상 정도 평가 및 모델 구조 확정		• 행동 분포 기준(sparse / medium / dense) intent의 그룹별 효과 분석 • user intent 구성 요소별 기여도 분석 • 사례 기반 case study

전체 실험 구조

실험 목표

- 전체 데이터를 활용한 시퀀스 기반 모델을 구현하고, 해당 성능을 upper bound로 정의
- 데이터가 sparse한 환경에서도 해당 upper bound 성능에 근접하는 것을 목표로 함

	Model A	Model B	Model C
model	DeepFM	DeepFM	BST
data	Sparse	Sparse	Full
Intent feature	X	O	X
Click sequence	X	X	O
type	Baseline	Enhanced	Upper bound

데이터셋 및 평가 지표



Taobao Dataset

- 알리바바 Taobao 플랫폼 실제 광고 클릭 로그 데이터
- 2017년 5월 6일 ~ 2017년 5월 13일 (약 8일간)
시간 단위로 기록된 사용자 행동 및 광고 노출 데이터

상세 구분

Raw Sample	user, adgroup_id, time_stamp, clk
Behavior Log	user, cate, btag (pv / fav / cart / buy)
Ad Feature	adgroup_id, cate_id, campaign_id, brand, price
User Profile	userid, age_level, shopping_level, gender

데이터셋 및 평가 지표

AUC

클릭된 샘플이 비클릭 샘플보다 높은 점수를 받을 확률을 측정
0.5는 무작위 수준, 1에 가까울수록 우수한 성능을 의미

0.50 = 무작위,
0.55~0.60 = 약하지만 구분력 있음
0.60~0.70 = 실무적으로 쓰이는 성능
0.80 이상 = 강한 성능
(보통 Criteo* 같은 공개 벤치마크에서나 보이는 성능)

Log Loss

예측 확률과 실제 값 간 차이를 측정하는 확률 기반 손실 함수

ECE

예측 확률과 실제 발생 빈도 간 차이를 측정
낮을수록 예측 확률이 실제 확률을 잘 반영함을 의미

*Criteo는 디지털 광고 및 커머스 마케팅 분야에서 AI 기반의 솔루션을 제공하는 글로벌 기술 기업
특히 광고 클릭률(CTR) 및 전환율 예측 모델을 연구하는 머신러닝/데이터 과학 분야에서 대규모 공개 데이터셋 제공

Upper Bound Model

비교 실험

DIEN	BST
- GRU로 사용자의 관심 변화 흐름을 시간 순서대로 학습 - 각 스텝의 잠재 관심사를 보조 손실로 명시적 학습 - 시간 간격 정보는 반영하지 못하고, 순서 정보만 고려함	- Transformer로 시퀀스 내 아이템 간 관계를 병렬 포착 - 타겟 아이템과 과거 행동 간 attention으로 관련도 계산 - 시간 간격 반영 가능 (실제 timestamp 차이 활용)

시간 기반 분할

- Train : 5/6 ~ 5/11
- Test : 5/12 ~ 5/13

시퀀스 구성

- 사용자 행동 로그를 Timestamp 기준 오름차순 정렬
- 각 타겟 이벤트 이전의 최근 N개 행동을 시퀀스로 구성
- 시퀀스 길이 < N인 경우 -> 패딩(Padding) 적용


Upper Bound Model

DIEN

AUC : 0.5966
Log loss: 0.2976
ECE: 0.1552

BST

AUC: 0.7103
Log loss: 0.016
ECE: 0.003



결과 분석

BST 성능이 더 좋았던 이유 : 시간 간격 반영

1. 유저 의도의 '유효성' 파악

실제 시간 차이를 계산해, 오래된 기록은 가중치를 낮추고
최근에 집중적으로 한 클릭은 현재의 구매 의사로 즉각 반영함

2. 행동 밀도에 따른 '맥락' 구분

몇 분 사이의 집중 탐색과 며칠 간격의 간헐적 방문을 구분하여,
단기적 필요와 장기적 취향을 동시에 정교하게 포착함

SPARSE DATA

활용 가능한 정보

- 상품 정보 (카테고리, 브랜드, 가격대 등)
- 컨텍스트 (시간대, 디바이스, 지면)
- 행동 집계 count (카테고리별 클릭 수, 구매 수 등)

활용 불가능한 정보

- 클릭/구매 시퀀스 (순서, 시간 간격 포함)
- 검색 이력
- 유저 인구통계

실제 광고 환경에서 ID 기반 추적이 제한될 경우를 상정해
특정 데이터가 임계치 이하로 떨어지는 상황을 재현

SPARSE DATA

활용 가능한 정보

- 상품 정보 (카테고리, 브랜드, 가격대 등)
- 컨텍스트 (시간대, 디바이스, 지면)
- **행동 집계 count** (카테고리별 클릭 수, 구매 수 등)

활용 불가능한 정보

- 클릭/구매 시퀀스 (순서, 시간 간격 포함)
- 검색 이력
- 유저 인구통계

유저 그룹

그룹	행동 수 (개)	유저 수 (명)
Sparse	~ 229	37만
Medium	230 ~ 629	39만
Dense	630 ~	38만

유저의 시간단위 행동이 담긴 데이터가 아닌
전체 행동을 집계한 요약 데이터 형태로 구성

Baseline Model

Wide&Deep

도메인 지식을 바탕으로 직접 선택한 피처 조합을
선형 모델과 신경망으로 동시에 학습하는 구조

- 1) **Wide Part:** 선형 모델을 사용해 특정 피처 사이 조합을 수동 선택하여 강한 상관관계를 명시적으로 암기함
- 2) **Deep Part:** 여러 층의 신경망을 통해 피처 간 고차원 비선형 관계를 학습하여 데이터에 없는 패턴을 일반화함

DeepFM


FM의 자동 피처 조합과 DNN의 비선형 학습을 결합한 형태

- 1) **FM Part:** 모든 피처 사이 2차 교호작용을 자동으로 학습
- 2) **Deep Part:** FM 파트와 임베딩 층을 공유해 연산 효율성을 높이고 고차원 피처 조합을 병렬로 학습함


Dataset 특성상 수동 feature cross가 어렵기에
자동 처리가 가능한 DeepFM을 채택

Baseline Model




DeepFM



Baseline Model




Baseline Model




Sparse한 데이터 환경에서 모델 성능이 저하됨을 확인

Baseline Model




Enhanced Model

DeepFM



Enhanced Model

DeepFM + Intent Feature



Enhanced Model

퍼널 구조 기반 파생변수 설정

threshold 기반 intent 정의

최종 intent text template

노출 → 탐색

$\text{Fav_rate} = \text{total_fav} / \text{total_actions}$ (전체 활동 대비 총 찜 비율)

$\text{Cate_diversity} = \text{top_cate } 1\sim 3 \text{ 존재 개수}$ (카테고리 다양성)

$\text{Cate_concentration} = \text{top_cate1_pv} / \text{total_pv}$ (전체 노출 대비 1순위 카테고리 비율)

관심 → 구매

$\text{pv_to_cart_rate} = \text{total_cart} / \text{total_pv}$ (노출 대비 장바구니 담은 비율)

$\text{Cart_to_buy_rate} = \text{total_buy} / \text{total_cart}$ (전체 장바구니 중 총 구매 비율)

$\text{Pv_to_buy_rate} = \text{total_buy} / \text{total_pv}$ (전체 노출 대비 총 구매 비율)

Enhanced Model

퍼널 구조 기반 파생변수 설정

threshold 기반 intent 정의

최종 intent text template

유저 현재 단계

cart_to_buy_rate > 0.3면 high conversion buyer

pv_to_cart_rate > 0.05면 active consideration shopper

fav_rate > 0.05면 wishlist collector

buy_rate > 0면 occasional buyer

그 외는 browser only

활동성

total_actions > 100 → highly active

total_actions > 30 → moderately active

그 외 → low activity

카테고리 집중도

cate_concentration > 0.7 → highly focused on one category

cate_concentration > 0.4 → moderately focused

그 외 → browsing across multiple categories

Enhanced Model

퍼널 구조 기반 파생변수 설정

threshold 기반 intent 정의


최종 intent text template

User is a {funnel_stage} with {activity} engagement.
Purchase funnel: views {total_pv} items,
adds {total_cart} to cart (view-to-cart: {pv_to_cart_rate}),
completes {total_buy} purchases (cart-to-buy: {cart_to_buy_rate}).
Saves {total_fav} items to favorites (fav rate: {fav_rate}).
Shopping pattern: {focus} across {cate_diversity} categories.
Top category engagement: viewed {top_cate1_pv} times,
purchased {top_cate1_buy} times.
Shopping level: {shopping_level}. Age group: {age_level}.

Sentence-transformer로
768차원으로 임베딩 후 PCA 진행

Enhanced Model

DeepFM + Intent Feature



Enhanced Model


모델별 성능 비교

Baseline Model


- AUC: 0.6424
 - AUC [sparse]: 0.5829
 - AUC [medium]: 0.6273
 - AUC [dense]: 0.6425
- log loss: 0.1943
- ECE: 0.0122

Enhanced Model


- AUC: 0.6592
 - AUC [sparse]: 0.5916
 - AUC [medium]: 0.6396
 - AUC [dense]: 0.6476
- log loss: 0.1925
- ECE: 0.0076




Enhanced Model



AUC 회복률




Paired Bootstrap



모든 집단에서 0 이상의 결과값을 가져
Enhanced Model의 성능이
Baseline Model보다 높아진 것은
우연에 의한 결과가 아님을 확인

피처 기여도

Ablation Result



Sparse

buy_rate 제거 시 하락폭이 가장 큼
→ 클릭 수가 적은 유저일수록 "몇 번 봤냐"보다 "얼마나 진지하게 행동했냐"가 더 중요한 신호

Medium

카테고리 분포 피처의 기여가 상대적으로 높음
→ 일정 정도 행동이 있는 경우 카테고리 맥락이 도움

Dense

어떤 피처를 제거해도 하락폭이 작음
→ 행동 데이터가 풍부하면 LLM 피처의 한계 효용이 낮음

케이스 스터디

CASE 1: Sparse User

항목	내용
총 행동 수	87회
주요 카테고리	스킨케어 pv 41회, 여성의류 pv 23회, 영양제 buy 2회
buy_rate	0.023
cart_rate	0.034
shopping_level	2

실제 정답: 스킨케어 광고, 영양제 광고

	모델 A 추천	모델 B 추천
1순위	남성의류	스킨케어
2순위	전자기기	영양제/건강식품
3순위	스포츠용품	여성의류

행동 데이터가 적어 Baseline model은 유사 유저 풀을 잘못 매핑
Enhanced Model은 카테고리 집중도와 buy_rate를 텍스트로 해석해 의도를 반영

케이스 스터디

CASE 2: Dense User

항목	내용
총 행동 수	1,243회
주요 카테고리	전자기기 pv 312회 / buy 18회, 스포츠 pv 189회
buy_rate	0.071
cart_rate	0.112
shopping_level	5

실제 정답: 전자기기 광고, 스포츠 브랜드 광고

	모델 A 추천	모델 B 추천
1순위	전자기기	전자기기
2순위	스포츠용품	스포츠용품
3순위	아웃도어	아웃도어

행동 데이터가 충분하므로 Baseline Model도 이미 유저 패턴을 잘 학습
Intent 피처가 추가 정보를 제공하긴 하지만 기존 ID 기반 패턴과 중복되어 기여가 미미

케이스 스터디

CASE 3: Sparse User

항목	내용
총 행동 수	143회
주요 카테고리	전자기기 pv 98회 / buy 9회 (전체 행동의 75% 집중)
buy_rate	0.063
cart_rate	0.091
shopping_level	3

실제 정답: 전자기기 광고

	모델 A 추천	모델 B 추천
1순위	전자기기	전자기기
2순위	전자기기 액세서리	전자기기 액세서리
3순위	게이밍	게이밍

행동이 적더라도 카테고리가 극단적으로 집중되어 있으면
Baseline Model도 유사 유저 군집을 올바르게 찾아냄

케이스 스터디

Case Study 결론

구분	조건	결과	시사점
Case 1	Sparse + 카테고리 분산	모델 B 우세	피처가 빈약하고 분산되면 의도를 보완하는 역할
Case 2	Dense + 카테고리 집중	모델 A $\approx$ B	행동 데이터가 충분하면 텍스트 임베딩 기여 미미
Case 3	Sparse + 카테고리 집중	모델 A $\approx$ B	행동이 적어도 신호가 집중되면 FM이 포착 가능

시맨틱 임베딩이 가장 효과적이기 위해서는
행동이 적고, 카테고리도 분산되어 있어서 ID 기반 모델이 유저를 잘못 읽는 경우를 타겟해야 함

CTR to Revenue

Sparse 유저 수

- 타오바오 MAU 약 9억 명 (2023년 기준)
- 그 중 sparse 유저 비율 $9\text{억} \times 0.7\% = \text{약 } 630\text{만 명}$


Sparse 유저 수

630만 명

CTR to Revenue

광고 노출 및 클릭 수

- 630만 명 × 하루 노출 20회 = 1억 2,600만 회/일 노출
- CTR 0.2% 기준 기존 클릭: 약 25만 건/일
- AUC +0.0162 → 추가 클릭: 약 7,500건/일
- 연간 추가 클릭: 약 270만 건/년



CTR to Revenue

광고 효과에 따른 수익

- 타오바오 커머스 광고 CPC 약 1,000~2,000원 가정
- 270만 건 × 1,500원 = 약 40억 원/년

⇒ 보수적으로 추정한 결과이니 전체 유저 대상으로 환산 시
CTR 한정 연간 약 1000억 이상의 추가 수익 확보 예상

Sparse 유저 수

630만 명

광고 노출 효과 개선에 따른
연간 추가 광고 클릭 수

270만 건

연간 추가 광고 수익

약 40억

의의 및 한계

- ID 기반 추천의 대안 전략을 실험적으로 검증
- “앞으로 어떻게 추천해야 하는가”에 대한 방향성 제시

**부족한 유저 데이터로 인해 ID 기반 협업 필터링 성능이 저하될 때
시맨틱 임베딩이 이를 얼마나 보완할 수 있는가**

의의 및 한계

- Sparse 환경을 행동 수 기준으로 인위적으로 구성했기 때문에 실제 privacy 환경과 분포 차이가 존재
- Taobao 데이터셋에 특화된 결과일 수 있으며, 다른 도메인 (콘텐츠 추천, 뉴스 등)에 대한 일반화는 검증되지 않음

**부족한 유저 데이터로 인해 ID 기반 협업 필터링 성능이 저하될 때
시맨틱 임베딩이 이를 얼마나 보완할 수 있는가**

의의 및 한계

부족한 유저 데이터로 인해 ID 기반 협업 필터링 성능이 저하될 때 시맨틱 임베딩이 이를 얼마나 보완할 수 있는가

- Ablation 기반 LLM 피쳐 기여도 분석으로 해석 가능성 확보
- Sparse 유저일수록 시맨틱 피쳐의 ROI가 높음을 정량적으로 입증
- 시맨틱 임베딩으로 분산된 행동 신호를 유저의 '의도'로 변환해 활용할 수 있음을 검증

의의 및 한계

부족한 유저 데이터로 인해 ID 기반 협업 필터링 성능이 저하될 때 시맨틱 임베딩이 이를 얼마나 보완할 수 있는가

- LLM 입력 템플릿 설계에 따라 성능이 달라질 수 있음
- LLM 피처가 실제 '유저 의도'를 정확히 반영했는지는 검증되지 않음
- LLM 기반 피처 생성은 실시간 광고 서빙에서는 latency 및 비용 문제가 존재

