Is Attention Explainable?

DSL 26-1 Modeling NLP1

14기 구기현 14기 권나연 14기 어희정 15기 조유빈

Introduction

딥러닝 모델의 발전과 함께 **모델의 블랙박스 문제**를 해결하려는 노력이 수반

특히 NLP에서도 모델의 근거를 보여줄 수는 없을까?

NLP

Classification

Labeling

Generation

Understanding

Inference

...

Introduction

딥러닝 모델의 발전과 함께 모델의 블랙박스 문제를 해결하려는 노력이 수반

특히 NLP에서도 모델의 근거를 보여줄 수는 없을까?

We focus on SOP!

NLP

Classification

Labeling

Generation

Understanding

Inference

...

Introduction

- **SOP(Sentence Ordering Problem)**

: 뒤섞인 문장들을 논리적이고 자연스러운 순서로 재배열하는 문제

- **Why this task is important?**

순서 이해는 모든 언어이해의 전제조건이기에 높은 추론을 요구
SOP Task 자체에 대한 성능 연구는 존재하나,

'모델이 문장 순서를 결정하는 과정이 인간의 추론 방식과 일치하는가'에
대한 설명력 관점의 연구는 거의 이루어지지 않음.

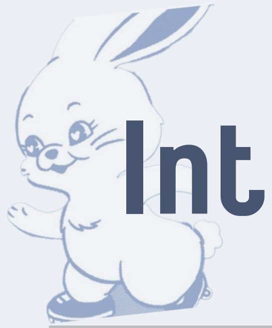

Introduction

대학수학능력시험 영어영역에서도 SOP 존재

수능영어 36 ~ 39번 (문장 삽입 유형, 순서배열 유형)

SOP는 언어의 논리구조에서 핵심적인 역할

오답률 순위	2019	2020	2021	2022	2023	2024	2025
1	31	34	38	34	33	32	33
2	34	37	34	29	34	31	34
3	39	40	21	37	37	34	32
4	41	24	32	31	36	37	24
5	33	33	30	33	38	33	37
6	30	31	24	38	32	24	40
7	37	38	39	41	42	15	39

Introduction

NLP 에서 Attention을 모델의 추론 근거로 생각할 수 있을까?

Is Attention 'Explanable'?

CV

NLP

Introduction

So... What is different?

모델의 설명력을
측정하고자 한 시도

Three types of Inference
(DL Model, 한국인 피험자, LLM)

Learning Method

- **목표**

두 문장(Pair) 간의 상대적 순서를 예측

$$P(s_i \prec s_j) = \sigma(W \cdot [v_i; v_j] + b)$$

- **손실함수**

$$L = -\sum (y \log \hat{y} + (1-y) \log(1-\hat{y}))$$

Neural Sentence Ordering

Xinchi Chen, Xipeng Qiu, Xuanjing Huang
Shanghai Key Laboratory of Intelligent Information Processing, Fudan University
School of Computer Science, Fudan University
825 Zhangheng Road, Shanghai, China
{xinchichen13, xpqiu, xjhuang}@fudan.edu.cn

Abstract

Sentence ordering is a general and critical task for natural language generation applications. Previous works have focused on improving its performance in an external, downstream task, such as multi-document summarization. Given its importance, we propose to study it as an isolated task. We collect a large corpus of academic texts, and derive a data driven approach to learn pairwise ordering of sentences, and validate the efficacy with extensive experiments. Source codes[1] and dataset[2] of this paper will be made publicly available.

(1) He liked music when he was a boy. (2) People are shocked by his potential. (3) Chopin is a great musician in Poland. (4) When he was 15, he finished his first waltz.
Gold: (3) (1) (4) (2)

Table 1: Illustration of sentence ordering task. Multiple discourse coherence relations might appear in a single text. First sentence (3) declares a topic. Sentences (1) (4) are in chronological sequence. However, sentence (2) is a result, so it should be the last sentence so as to abide to a cause-effect relation.

Model Structure

Embedding Model

단어를 모델이 이해할 수 있는 벡터로 만들어 주는 것

BERT, LSTM, CNN 등 다양한 모델을 사용해 임베딩

$$sentence_i \oplus sentence_j$$

$$\downarrow$$

$$sentence \longrightarrow$$

EMBEDDING

$$token_1 \rightarrow vector_1$$
$$token_2 \rightarrow vector_2$$
$$\cdots \qquad \cdots$$
$$token_n \rightarrow vector_n$$

Model Structure

Embedding Model

"BERT"

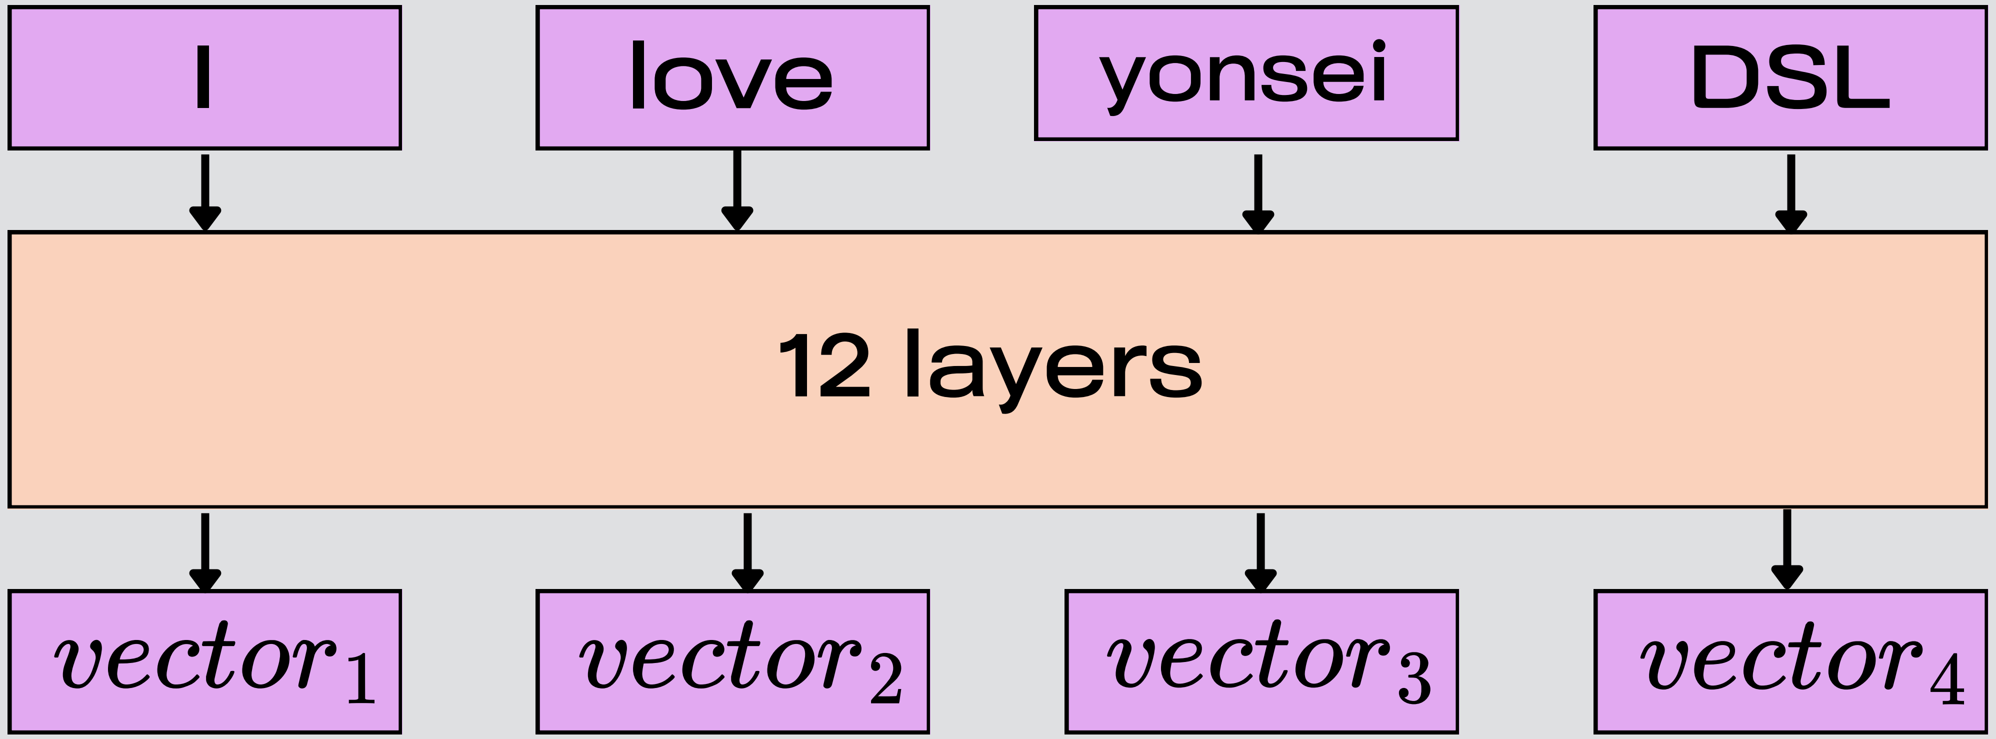

Model Structure

Embedding Model

"BiLSTM"

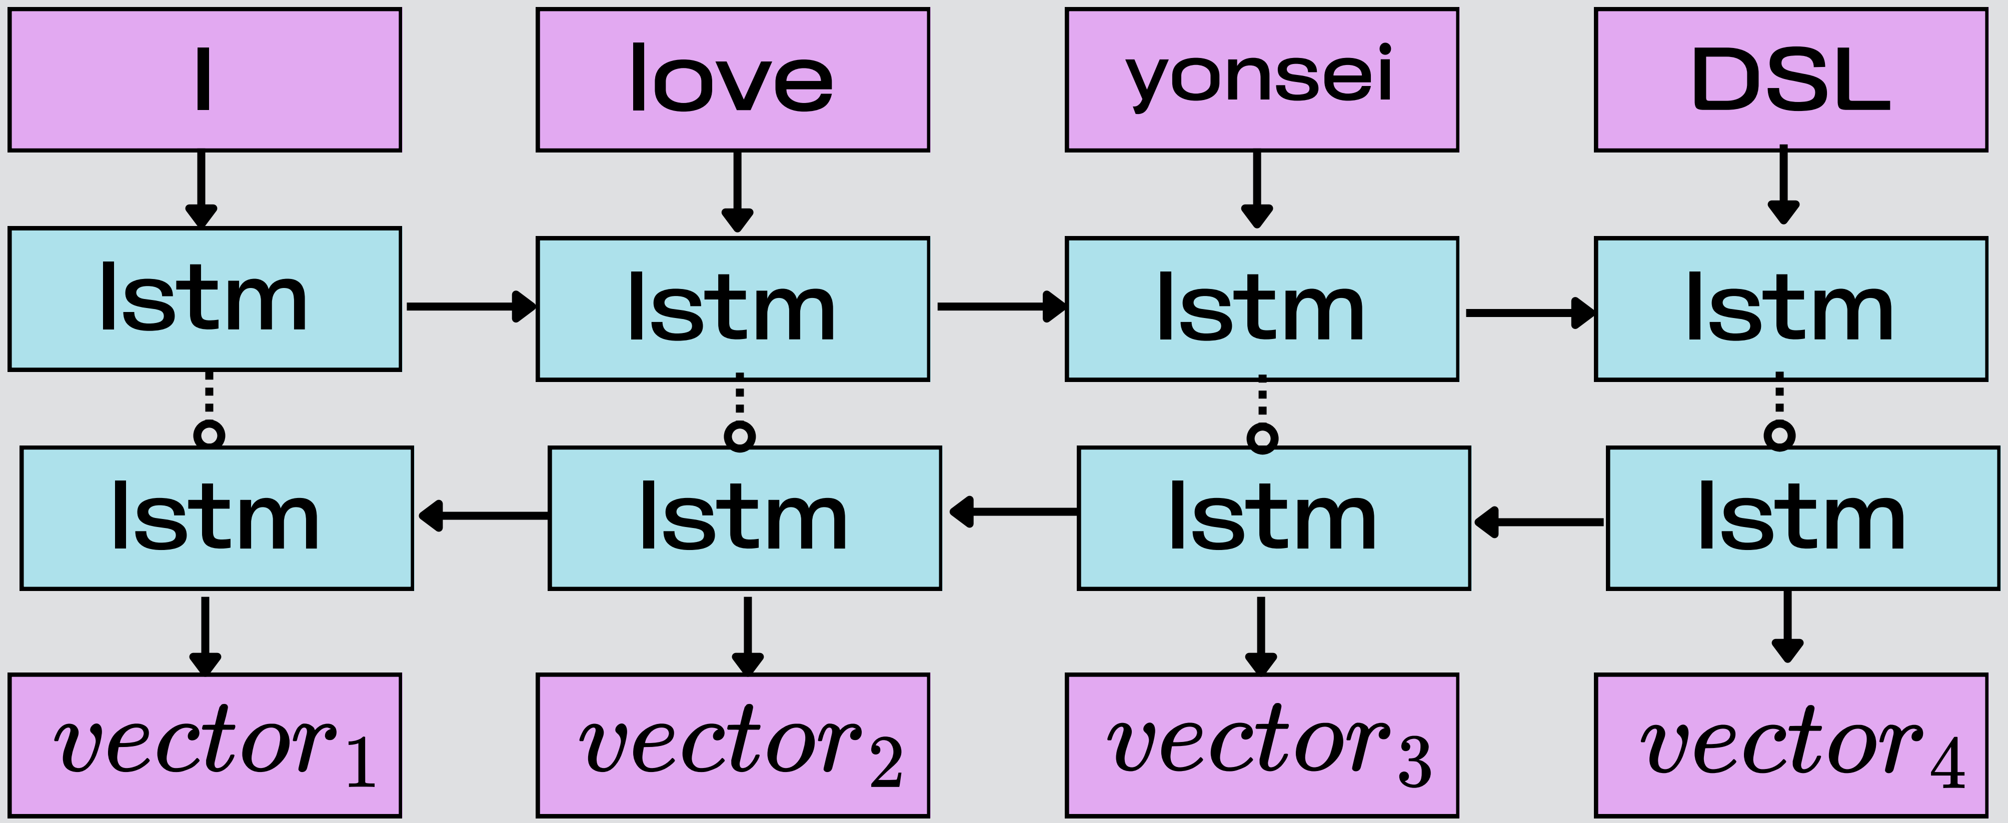

Model Structure

Embedding Model

"CNN"

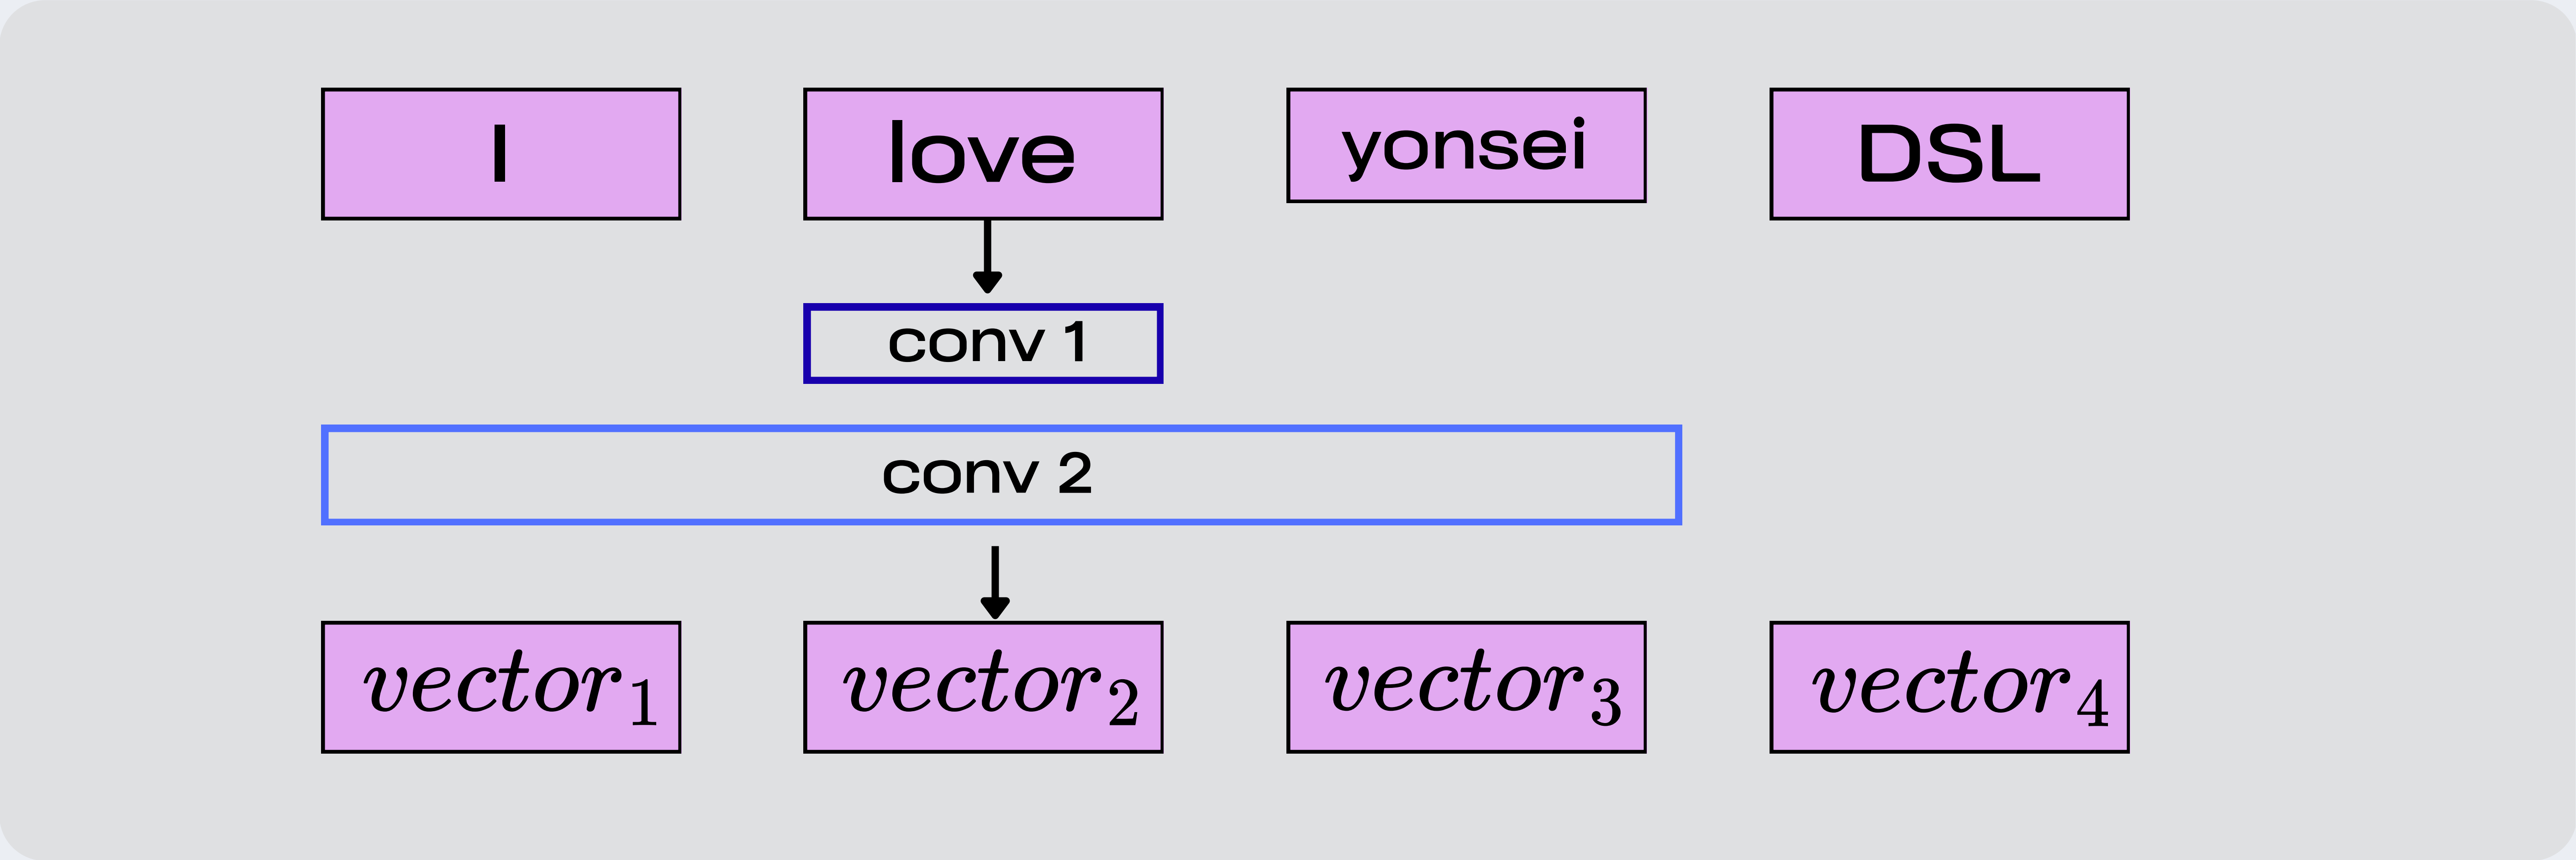

Attention

임베딩 된 벡터에 각각 어느 정도 가중치를 주어야 할 지 학습

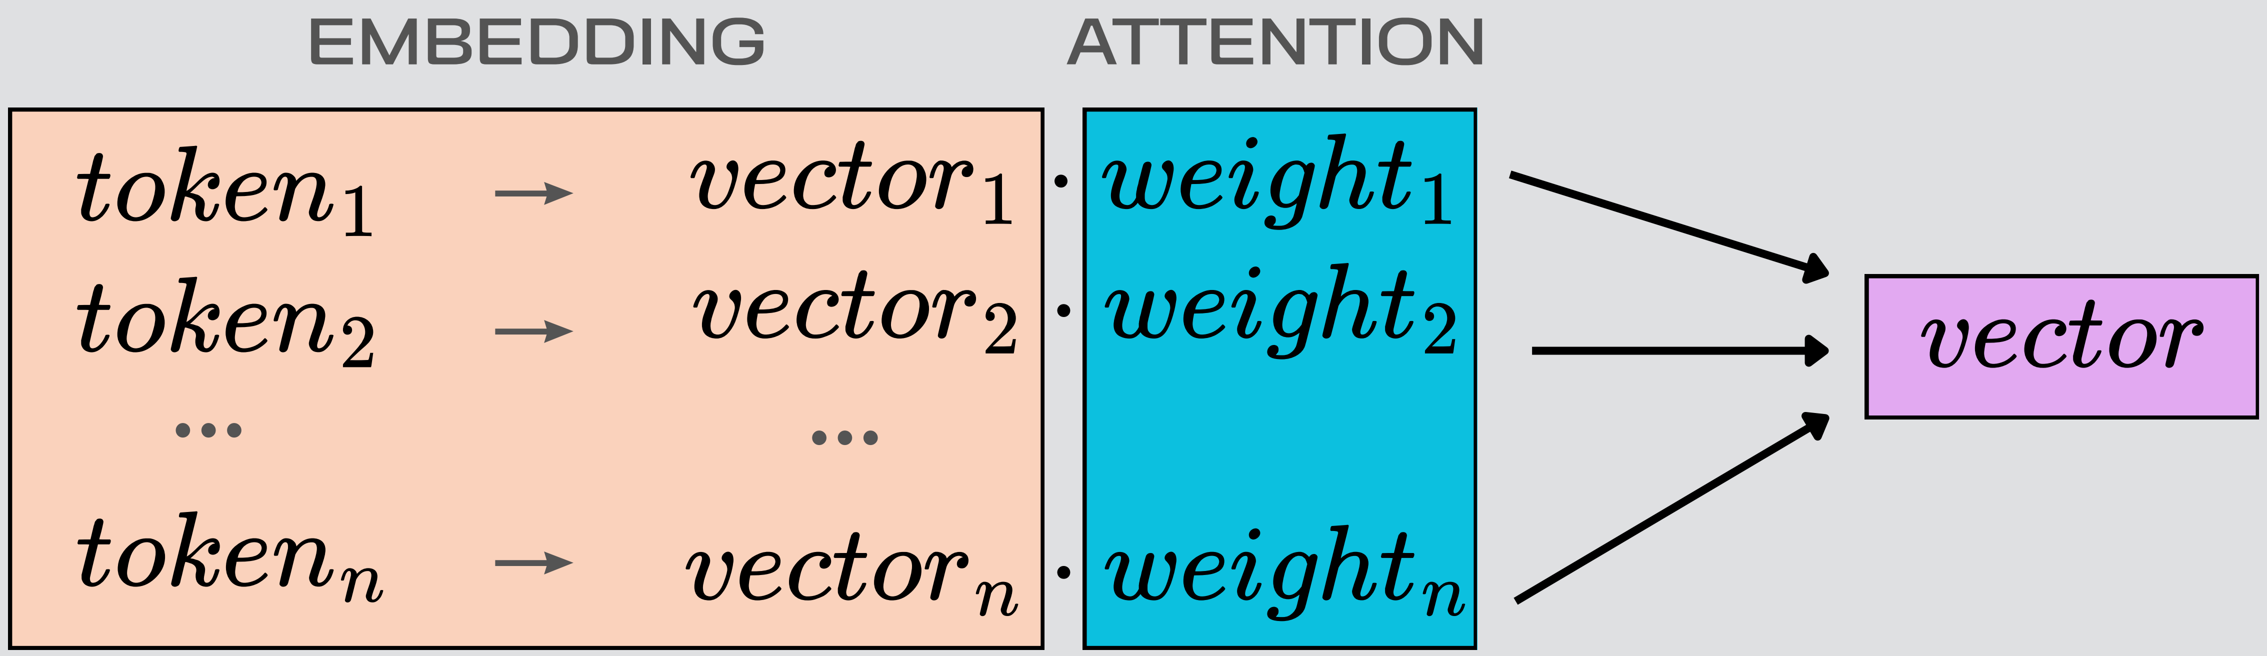

Model Structure

FNN

어텐션 가중합을 통해 도출된 하나의 벡터를 통해
'정순' '역순' 의사결정 (n차원 → 1)

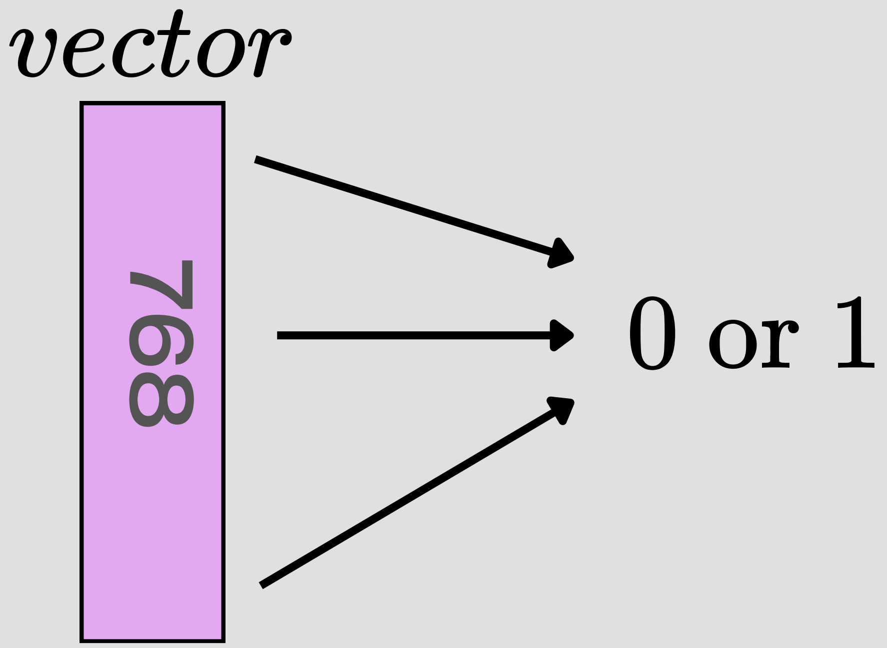

Gradient vs Attention

- **Gradient**

임베딩 값이 조금 변할때, 결과 확률에 영향을 미치는 정도

- **Attention**

학습한 어텐션 가중치 값

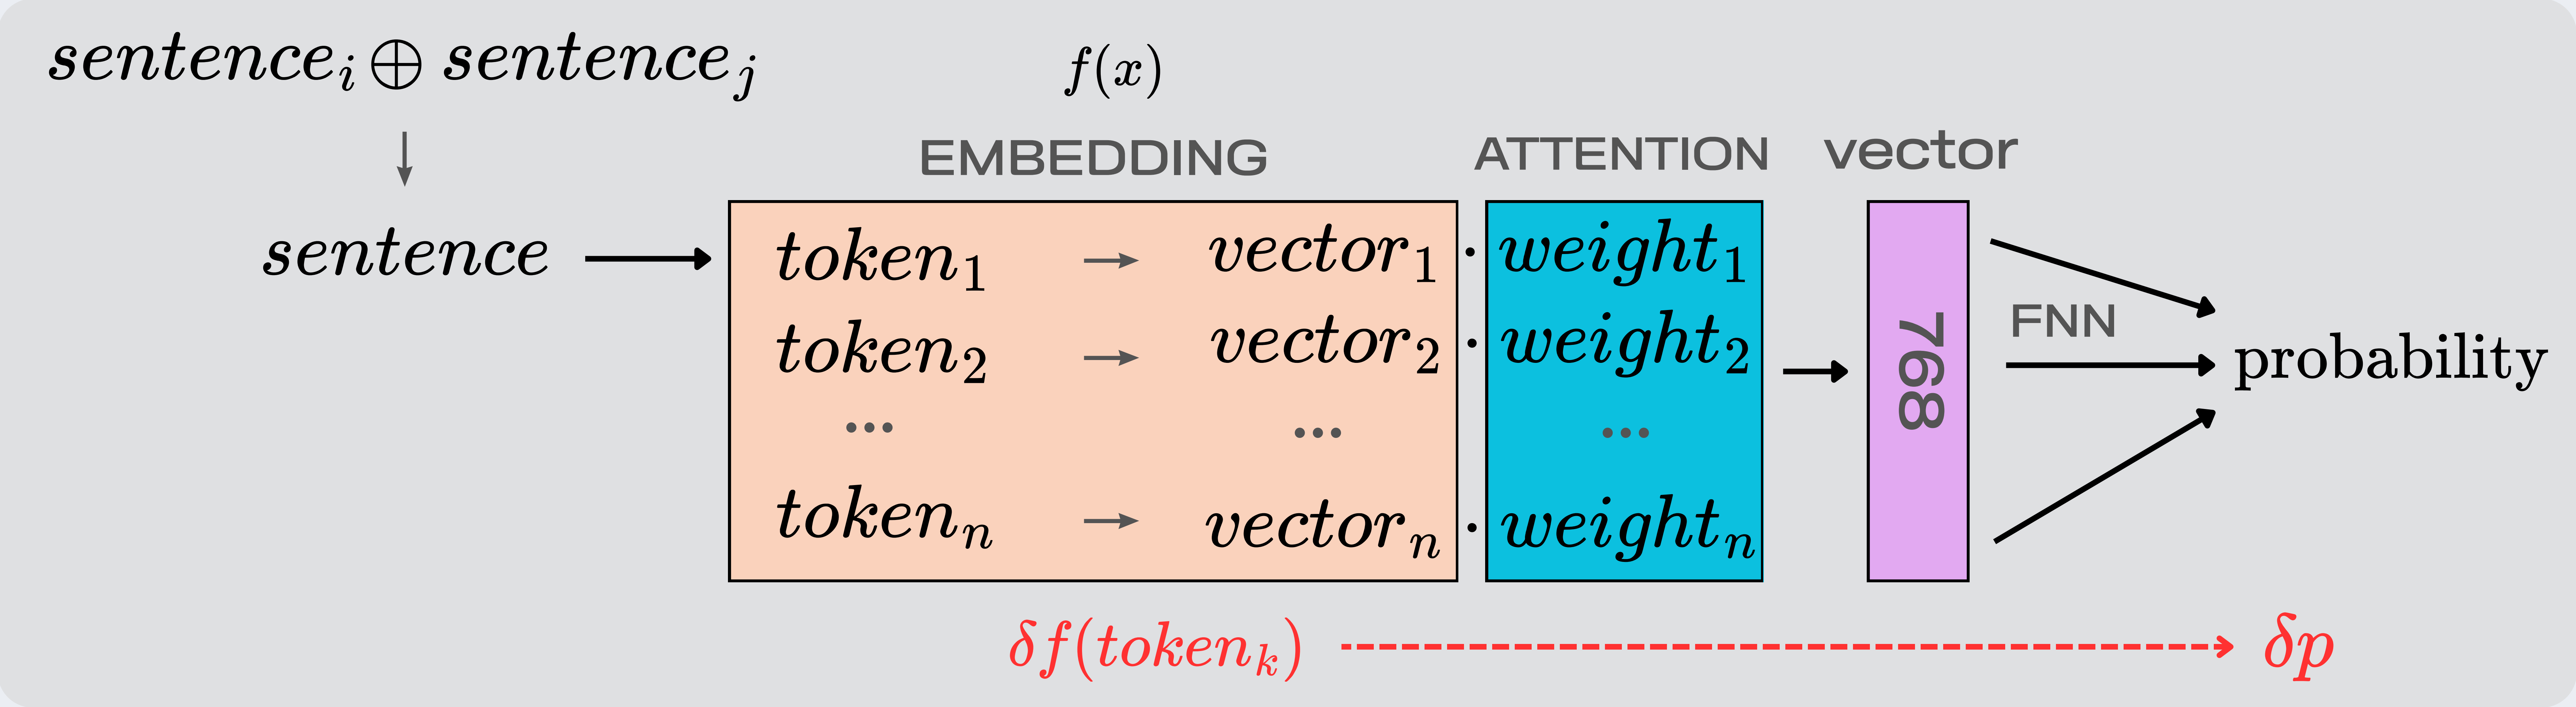

Data1. arXiv papers abstract 400,000

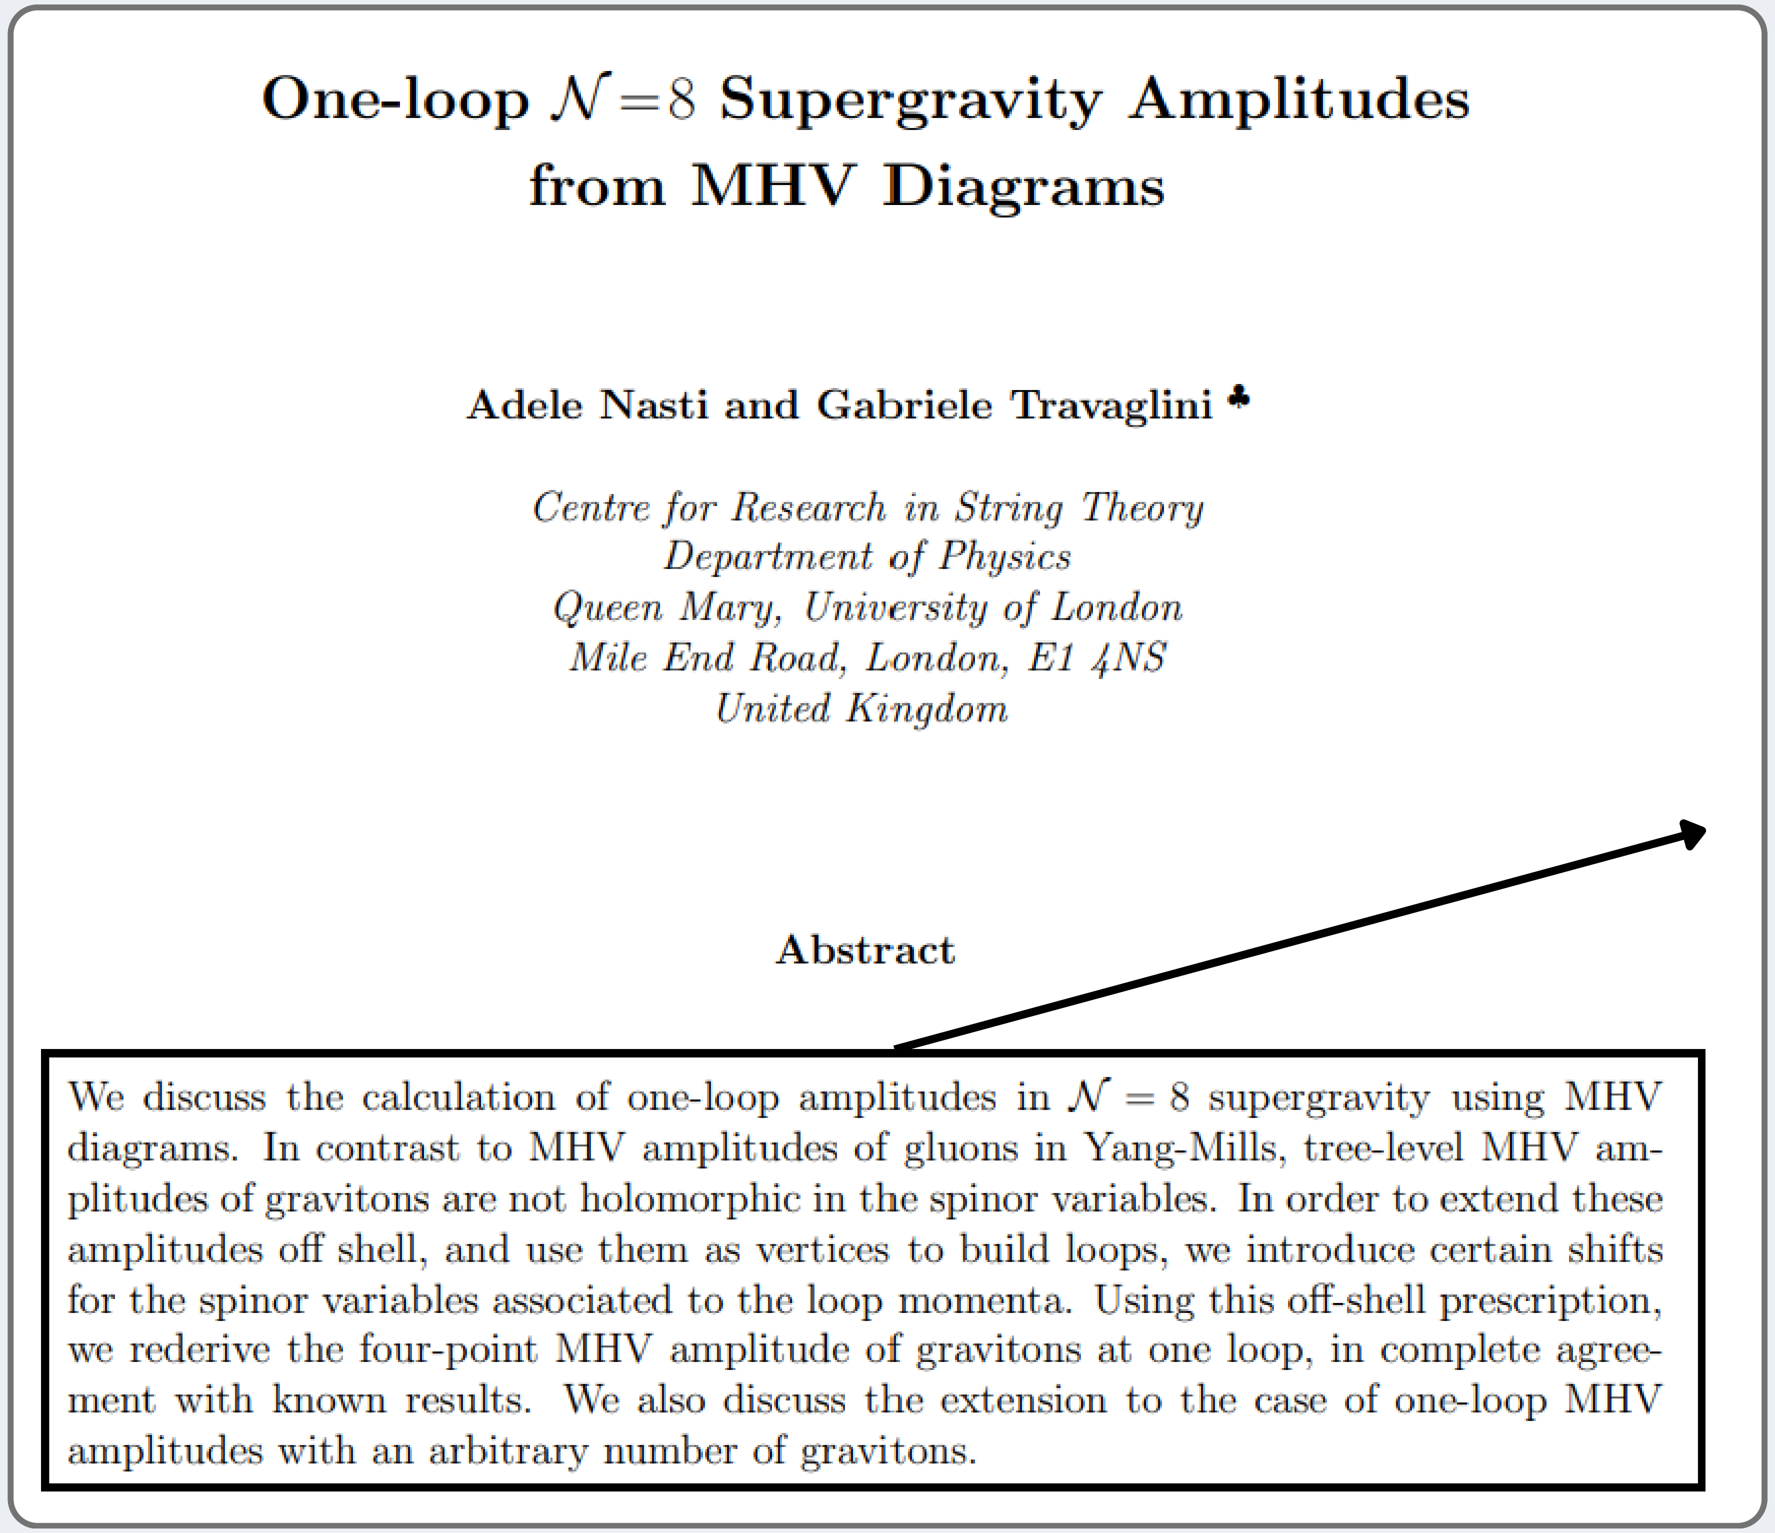

One-loop $\mathcal{N}=8$ Supergravity Amplitudes
from MHV Diagrams

Adele Nasti and Gabriele Travaglini ♣

Centre for Research in String Theory
Department of Physics
Queen Mary, University of London
Mile End Road, London, E1 4NS
United Kingdom

Abstract

We discuss the calculation of one-loop amplitudes in $\mathcal{N}=8$ supergravity using MHV diagrams. In contrast to MHV amplitudes of gluons in Yang-Mills, tree-level MHV amplitudes of gravitons are not holomorphic in the spinor variables. In order to extend these amplitudes off shell, and use them as vertices to build loops, we introduce certain shifts for the spinor variables associated to the loop momenta. Using this off-shell prescription, we rederive the four-point MHV amplitude of gravitons at one loop, in complete agreement with known results. We also discuss the extension to the case of one-loop MHV amplitudes with an arbitrary number of gravitons.

잘라서 정순/역순 데이터 생성

We discuss the calculation of one-loop amplitudes in N=8 supergravity using MHV diagrams. In contrast to MHV amplitudes of gluons in Yang-Mills, tree-level MHV amplitudes of gravitons are not holomorphic in the spinor variables. In order to extend these amplitudes off shell, and use them as vertices to build loops, we introduce certain shifts for the spinor variables associated to the loop momenta. Using this off-shell prescription, we rederive the four-point MHV amplitude of gravitons at one loop, in complete agreement with known results. We also discuss the extension to the case of one-loop MHV amplitudes with an arbitrary number of gravitons.

Model Components: EMBEDDING, ATTENTION, FNN

train, valid, test : 1,846,272, 102,656, 102,656 pairs

batch size: 64

lr : BERT(2e-5) and BiLSTM, CNN (3e-5)

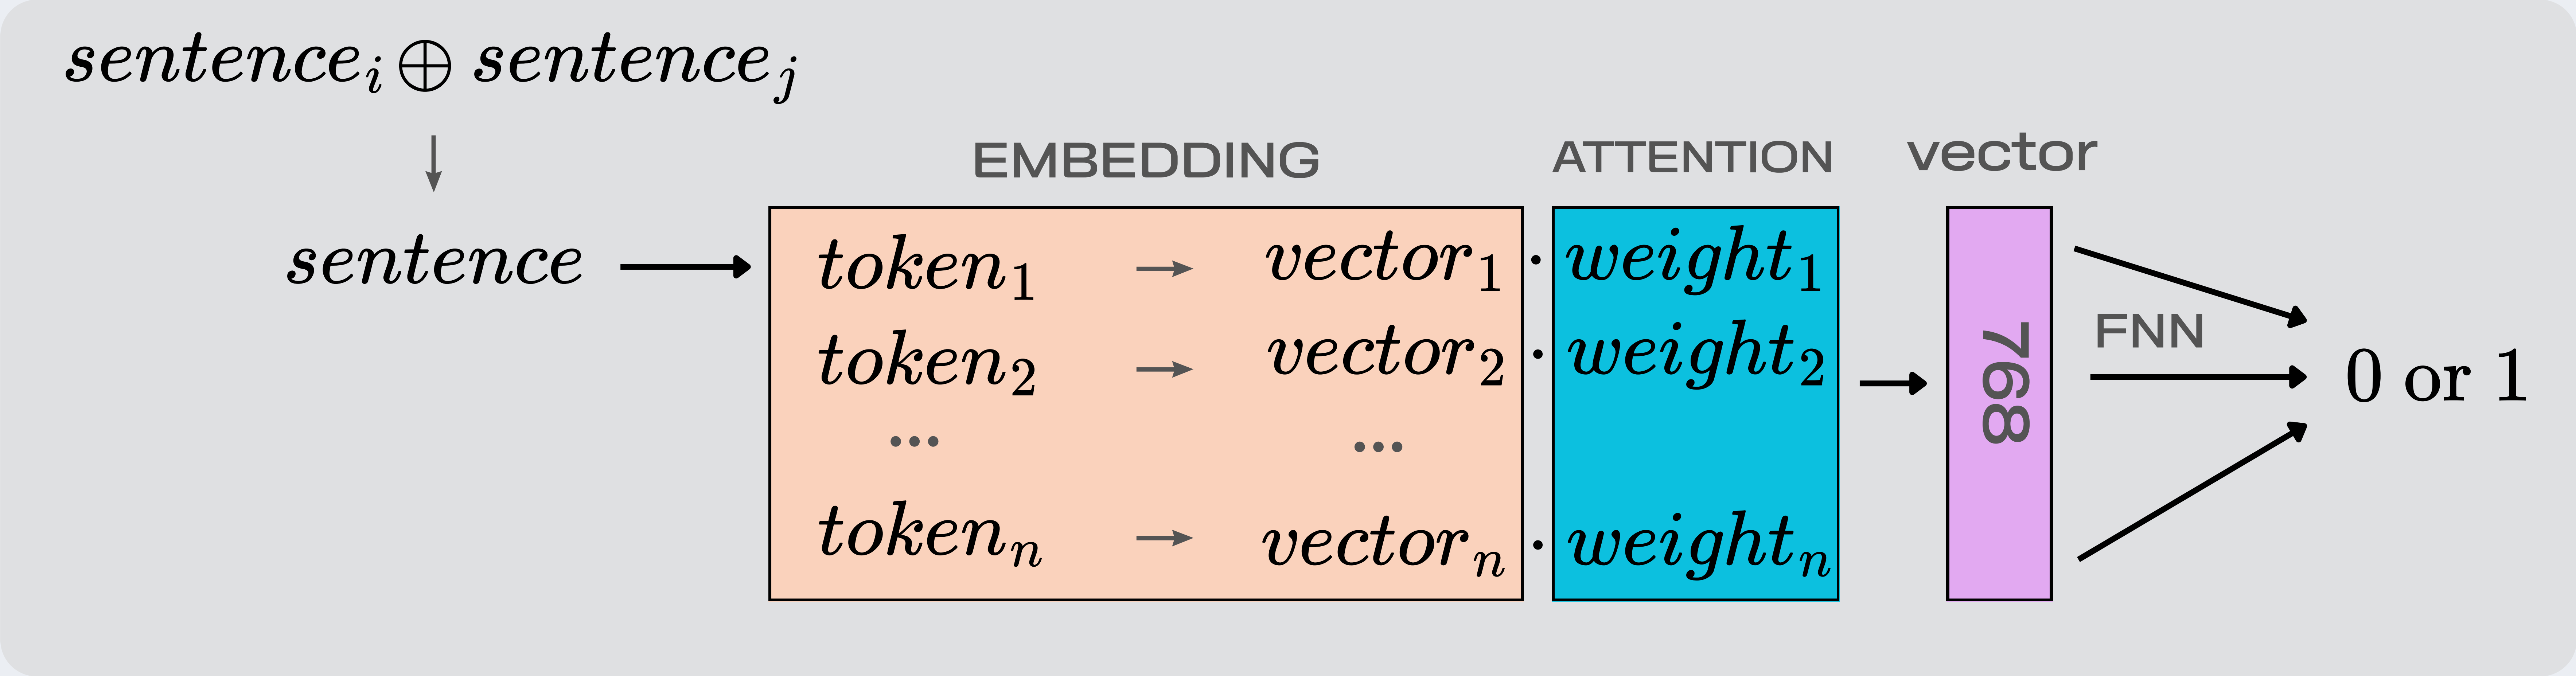

Data2. 2017 ~ 2025 교육청, 평가원 영어 기출

23. 다음 글의 주제로 가장 적절한 것은?

From your brain's perspective, your body is just another source of sensory input. Sensations from your heart and lungs, your metabolism, your changing temperature, and so on, are like ambiguous blobs. These purely physical sensations inside your body have no objective psychological meaning. Once your concepts enter the picture, however, those sensations may take on additional meaning. If you feel an ache in your stomach while sitting at the dinner table, you might experience it as hunger. If flu season is just around the corner, you might experience that same ache as nausea. If you are a judge in a courtroom, you might experience the ache as a gut feeling that the defendant cannot be trusted. In a given moment, in a given context, your brain uses concepts to give meaning to internal sensations as well as to external sensations from the world, all simultaneously. From an aching stomach, your brain constructs an instance of hunger, nausea, or mistrust.

* blob: 형태가 뚜렷하지 않은 것

① influence of mental health on physical performance
② physiological responses to extreme emotional stimuli
③ role of negative emotions in dealing with difficult situations
④ necessity of staying objective in various professional contexts
⑤ brain's interpretation of bodily sensations using concepts in context

From your brain's perspective, your body is just another source of sensory input. Sensations from your heart and lungs, your metabolism, your changing temperature, and so on, are like ambiguous blobs. These purely physical sensations inside your body have no objective psychological meaning. Once your concepts enter the picture, however, those sensations may take on additional meaning. If you feel an ache in your stomach while sitting at the dinner table, you might experience it as hunger. If flu season is just around the corner, you might experience that same ache as nausea. If you are a judge in a courtroom, you might experience the ache as a gut feeling that the defendant cannot be trusted. In a given moment, in a given context, your brain uses concepts to give meaning to internal sensations as well as to external sensations from the world, all simultaneously. From an aching stomach, your brain constructs an instance of hunger, nausea, or mistrust.

수능 영어 지문 스타일을 익히기 위함

학습

학습 파라미터 : BERT(2 lyrs), ATTENTION, FNN

train, valid, test : 9016, 1012, 1012 pairs

batch size : 32

lr : 1e-5 (1차 파인튜닝보다 더 낮게)

$$sentence_i \oplus sentence_j$$

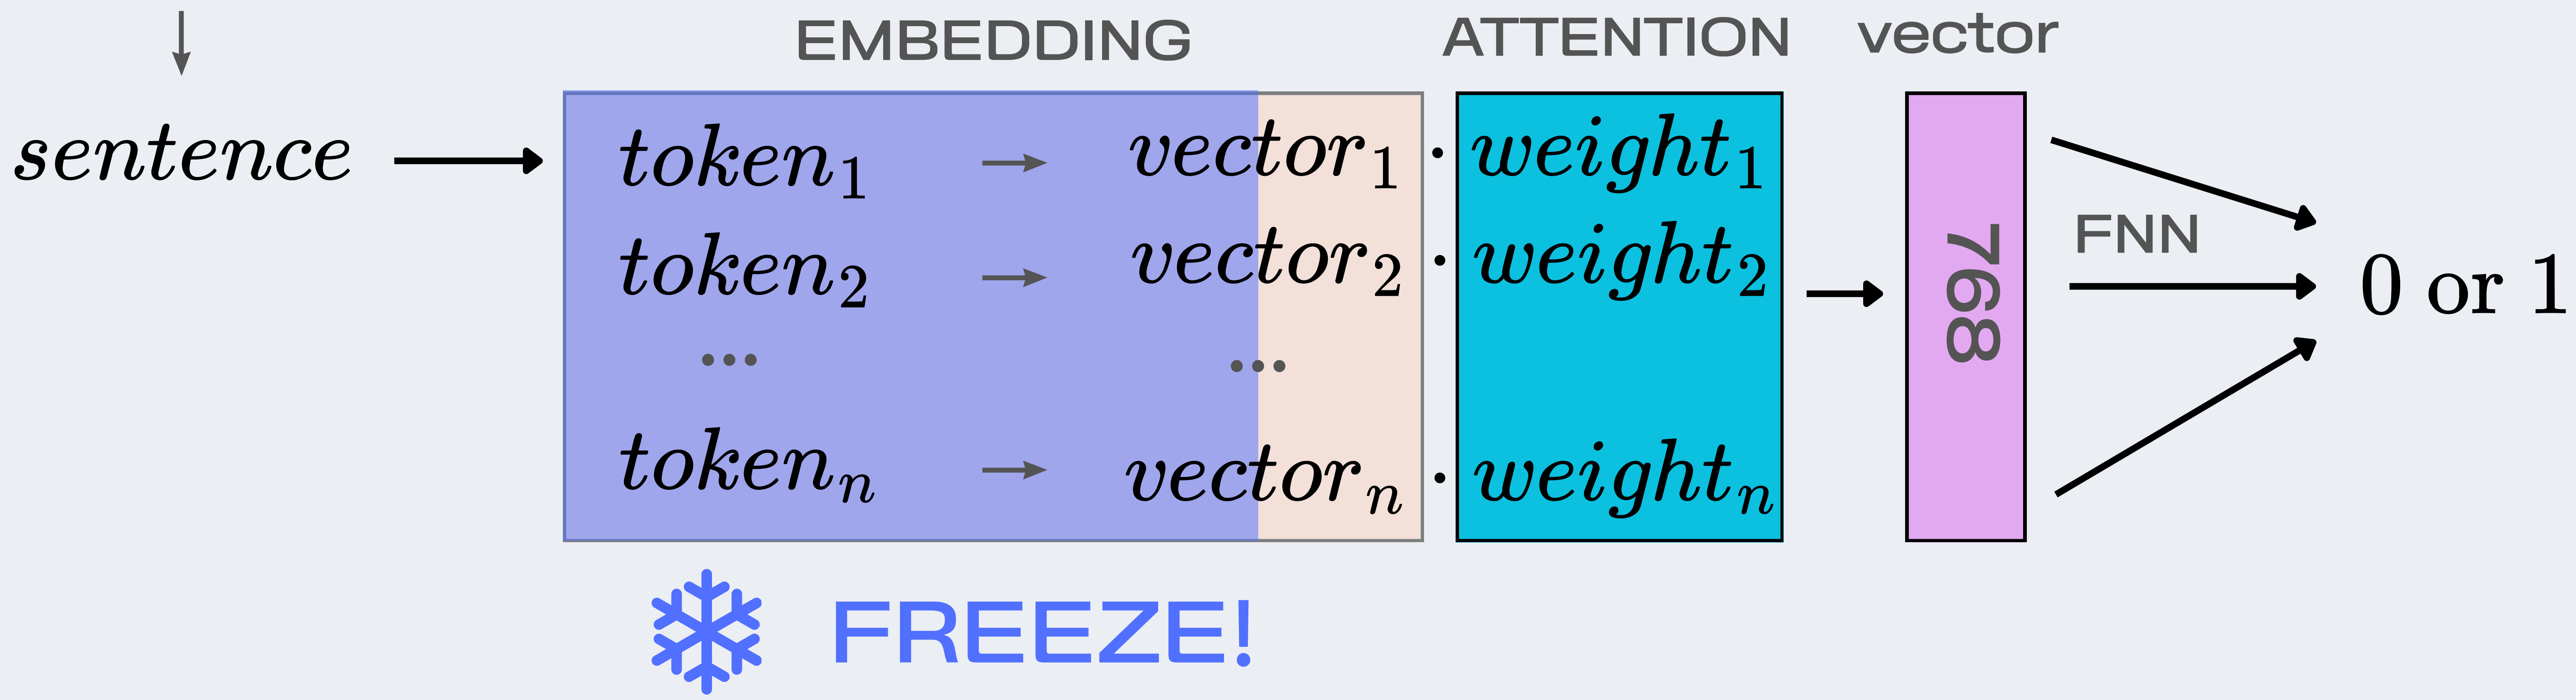

학습 결과

같은 테스트 셋으로 비교한 결과, 파인튜닝을
통한 전이학습이 잘 이루어졌음을 볼 수 있음.

Emb_models	base	fine tune 1	fine tune 2	Kendall τ
BERT	0.509	0.813	0.843	0.1732
BiLSTM	0.498	0.718	0.763	0.1956
CNN	0.501	0.654	0.703	0.2116

Kendall τ
주목한 단어 간의
순위 일치도 (-1 ~ 1)

attention과
gradient들의
관계가 낮다!!

실전 문제 풀이결과

- 순서배열

BERT : 70/116 (60.3%)
BILSTM : 20/116 (17.2%)
CNN : 25/116 (21.6%)

- 문장삽입

BERT : 57/119 (47.9%)
BILSTM : 23/119 (19.3%)
CNN : 30/119 (25.2%)

그럼 둘 중 ‘진짜’ 설명은??

25년도 09월 순서배열 37번

Emb_models	Attention	Gradient
BERT	to, that, the, a, are	methematics, methematical, first, recognise, simply
BiLSTM	you, put, would, not, complicated	put, to, not, that, you
CNN	you, put, the, would, complicated	you, would, put, not, the

LLM 과 비교

Why LLM?

: 특정 task에 대해 Fine-tuning 된 것이 아닌 종합적인 언어모델

우리가 자주 사용하는 LLM.
우리와 비슷한 사고로
수능 task도 잘 풀이할 수 있을까?

LLM과 비교

- 평가 대상 LLM 모델

Chat GPT

ChatGPT

Gemini

Gemini

Claude

Claude

- Prompt 예시

지금부터 수능 영어 문장삽입 문제를 푼다. 그리고 그 근거 단어들을 추출할 것이다. 반드시 아래 절차를 순서대로 수행하라.

태스크 정의

[1] 문제 이해 - raw_text를 읽고 글의 전체 흐름을 요약하라 (1~2문장)

[2] 삽입 문장 분석 - box_text의 핵심 기능을 정의하라 (예: 원인, 결과, 예시, 추가 설명, 대비, 문제, 해결 등)

[3] 각 위치별 평가 (해당 번호 ①~⑤ 모두) 각 위치마다 다음을 수행하라: - '해당 번호' 앞 뒤 문장의 핵심 내용 요약 - '해당 번호' 자리에 box_text가 들어갔을 때 자연스러운지 평가하라. 다시 말하지만 '해당번호 앞뒤에 들어가는게 아니라, 해당 번호에 번호를 지우고 box가 들어갔을때' - '연결 논리 전환', '주제 변경','문제해결' '글의 응집성', '지시어 비교' 등을 기준으로 적합도 점수를 구하라.

예시 풀이 로직

예1) box 가 A (A 는 대상이 될 수도 있고, 주제가 될 수도 있다.)에 대해 설명하고 있는데, 삽입하고자 하는 '해당번호' 앞 뒤로 B (B는 대상이 될 수도 있고, 주제가 될 수도 있다.) 에 대해 얘기하고 있다면, box 에서 전환의 시그널이 없고, box 뒤에 다시 전환의 시그널이 없는 한(시그널은 지시어나, 접속사가 되겠지) 해당 번호에 box 가 들어가면 자연스럽지 않을 것이다.

예2) box 에서 this 로 받고 있는 대상이 있으면, 적어도 삽입을 하고자 하는 번호 앞에 this 와 연결이 되는 대상이 구체적으로 나와야 할 것이다.

예3) 구체적인 사례의 성격을 box 가 가지고 있다면, 앞에 구체적 사례의 일반적 형식에 대해 나와야한다.

‘ 이러한 예시는 단순히 풀이의 예시일 뿐이지, 너가 무조건 이렇게 풀어야 한다는 것은 아님 ‘

출력 형식

[4] 너가 모든 '해당 번호' 에 box 를 넣어서 가능성이 가장 높은, 하나의 번호를 출력해줘

[5] CSV 출력 columns = problem, answer, reasoning - problem: 파일명_문제번호 - answer: 정답 번호 - reasoning: 가장 중요한 근거 단어/구 5개 (쉼표 구분)

[중요 규칙] - \n, \r 은 의미 없는 기호로 처리 - 괄호 번호 기준으로 위치 판단 - 절대 인터넷 검색 금지

결과 : 정답률

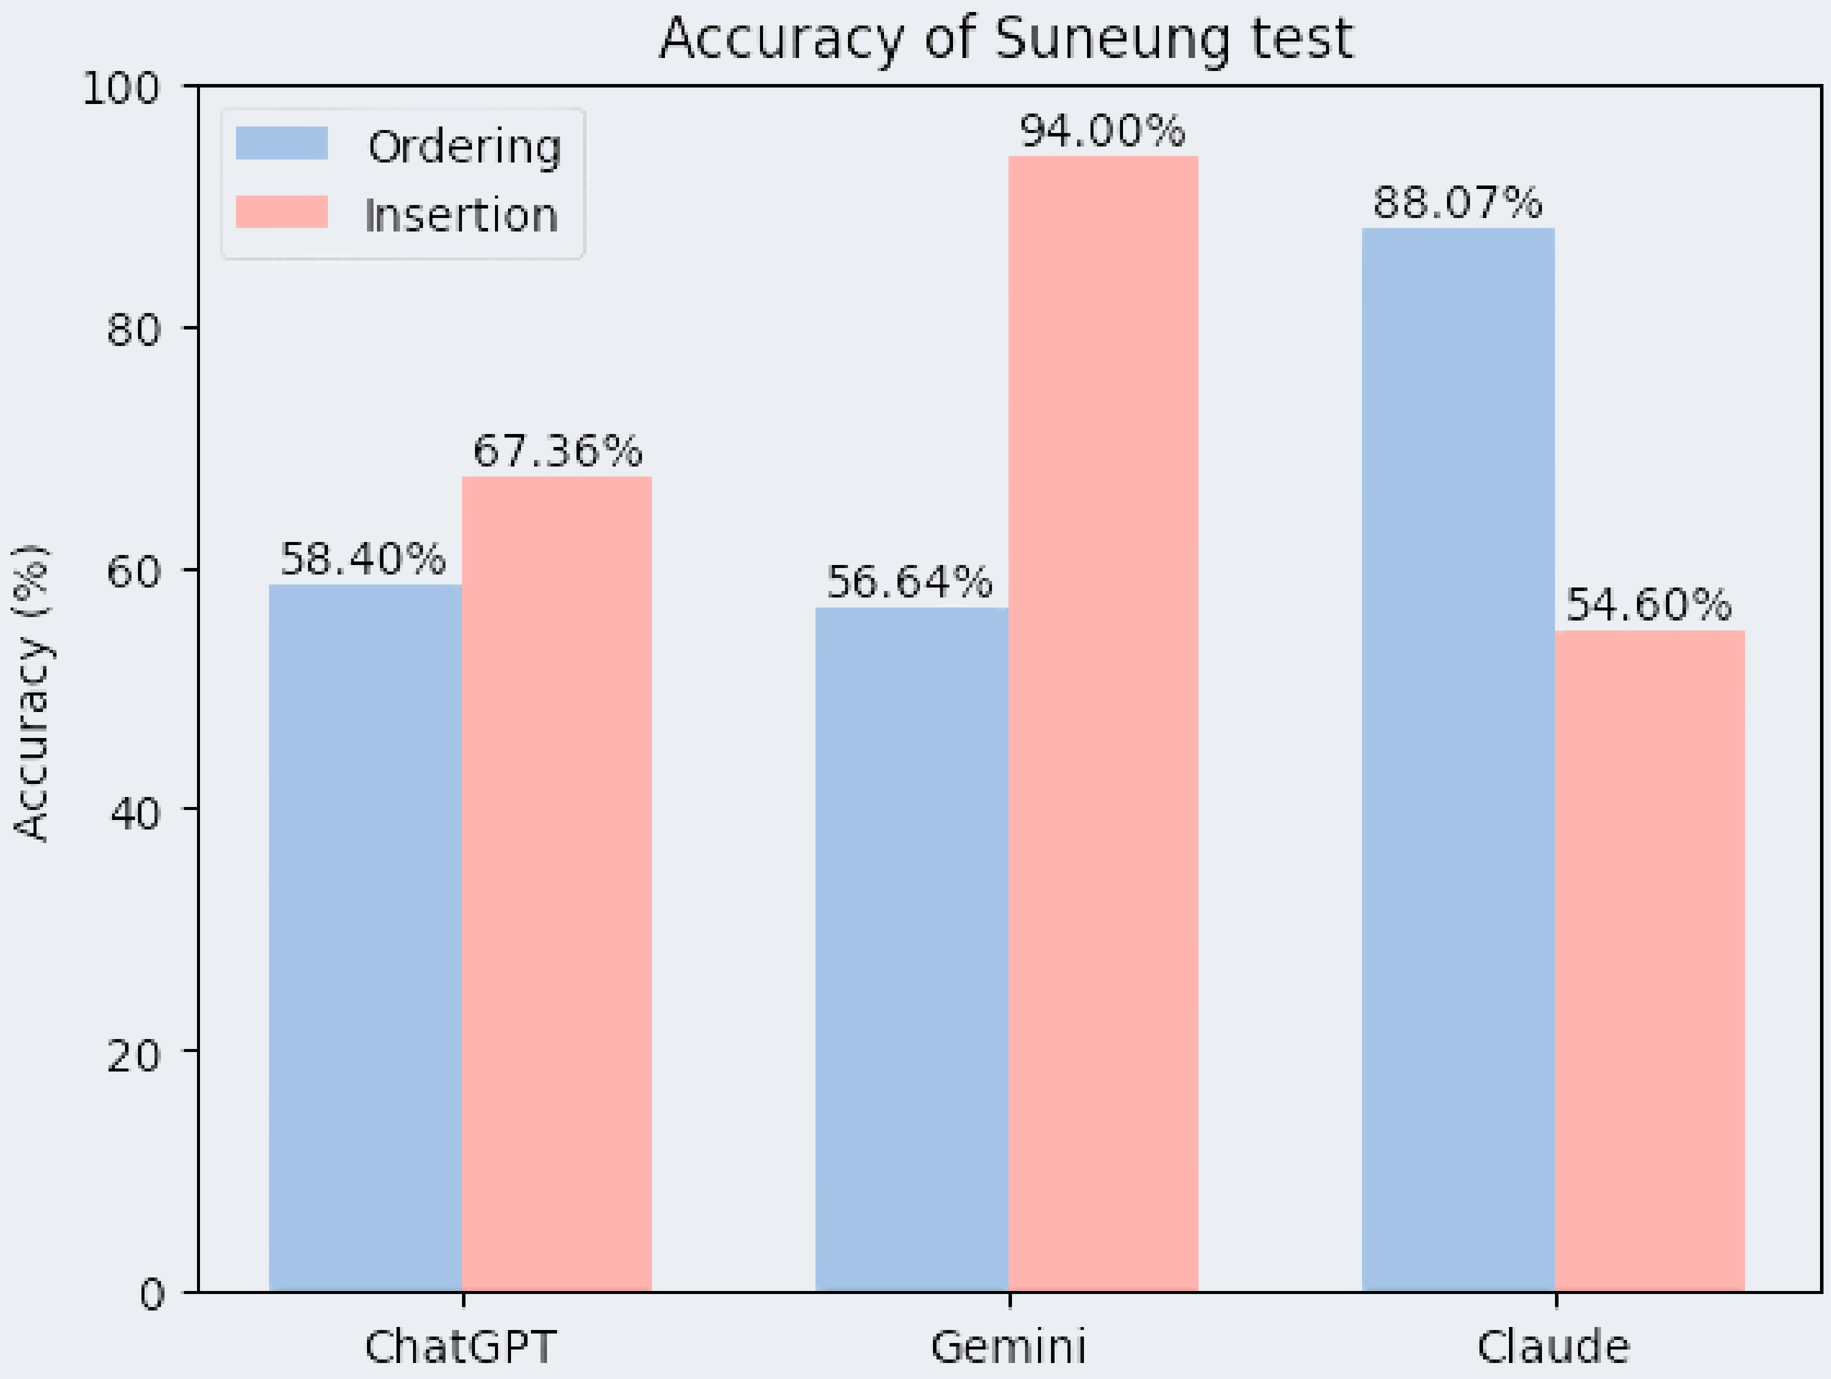

순서배열 117개 / 문장삽입 119개

각자 눈에 띄게 뛰어난 태스크가 존재하지만,

생각보다 그렇게 뛰어나지 않다 !!

결과 : 근거로 사용한 단어

2025년 9월 37번

Emb_models	top 5 words
CHAT GPT	math, confusion, notation, difficulty, recognition
Gemini	not undetstood, professional mathematicians, complicated notation, quite
Claude	You would not be first, how do you recognise, complicated notations, quite modern, Put simply something mathematical

결과 : Attention vs Gradiant

node : 모델명
edge : (문항 별 겹치는 단어 수/전체 단어 합집합)

Gradient WIN !

문장삽입

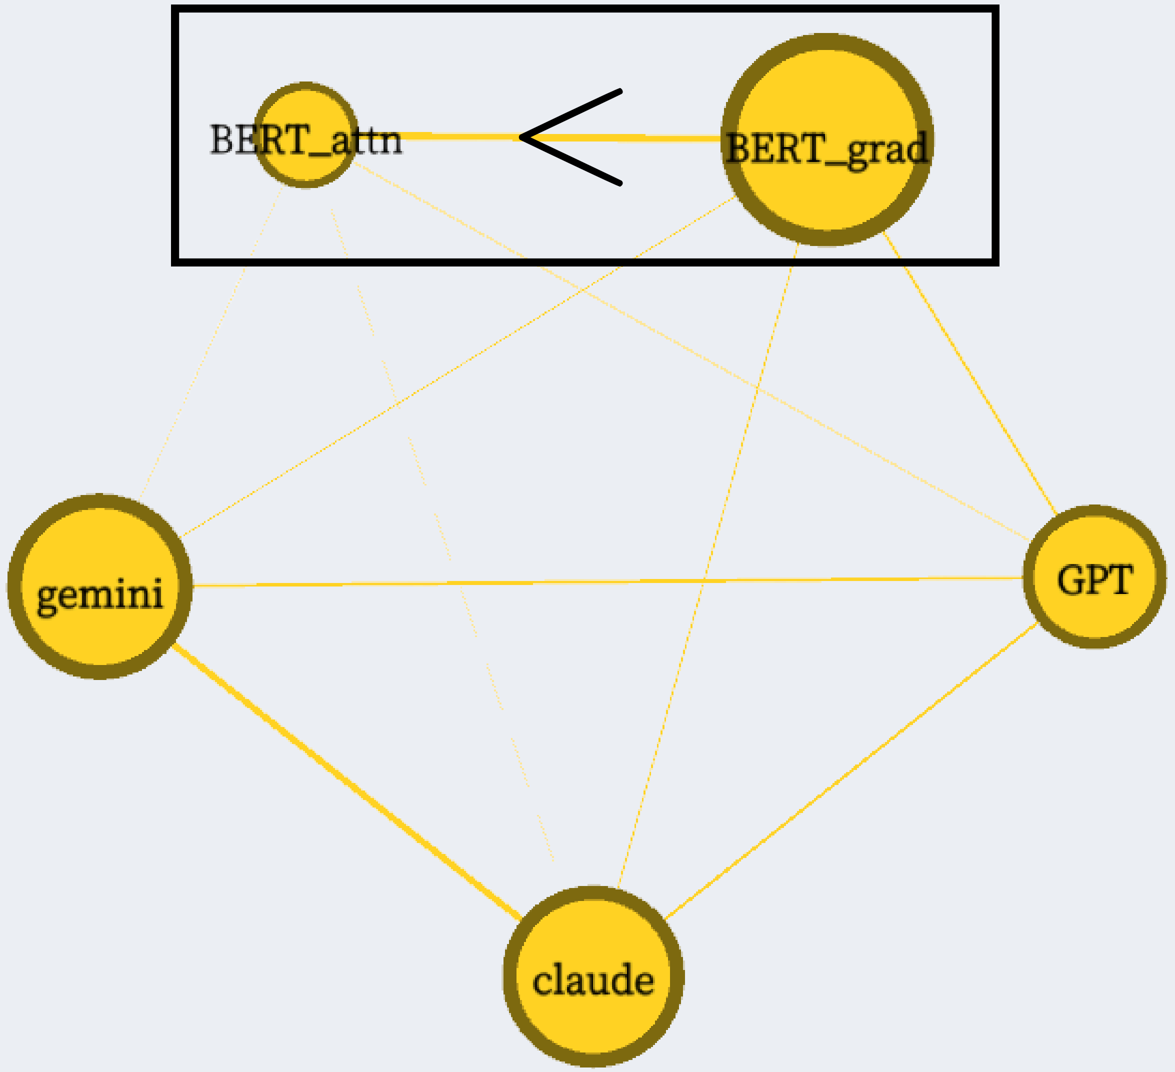

순서배열

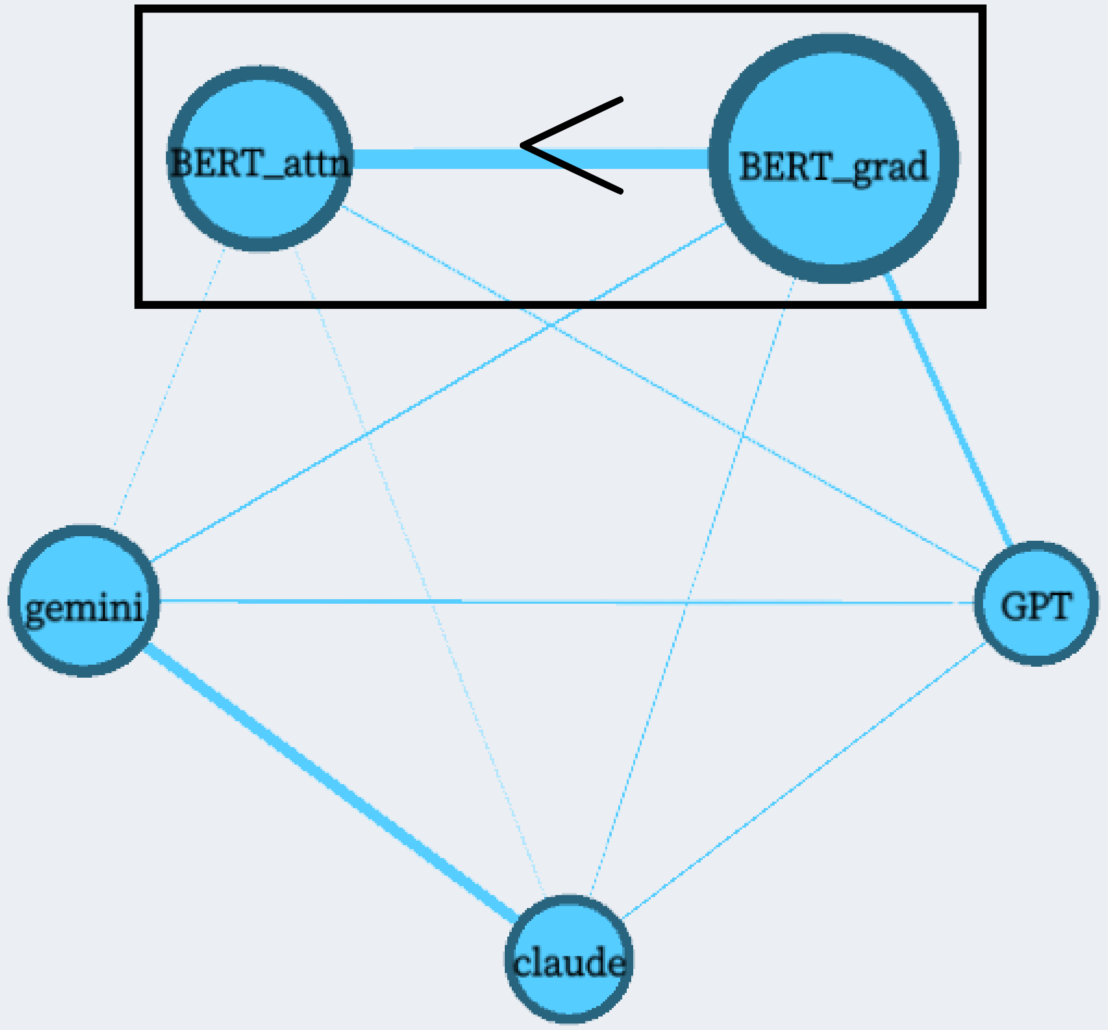

Human test

결국은 Explainable AI 가 되기 위해서는 실제 인간의 사고과정과 비교해야 의미가 있는 것!

순서배열 : 13명, 문장삽입 : 9명
2017년 : 07월 ~ 11월 (10문제씩)

But cute and beautiful designs also have downsides.

Research finds that people show a strong visceral interest in and desire to approach and own cute-looking and beautiful (elegant) designs. (①) However, cute and beautiful designs elicit two very different motivations. (②) A cute product or package design elicits a nurturing motivation — a desire to take care of and keep the product, to hold it dear to our hearts and never let it go. (③) The beautiful product or package design elicits a self-expressive, or signaling, motivation — a desire to express oneself to others through product ownership. (④) Certain types of cute products can be associated with a lack of sophistication or seriousness, which can reduce performance expectations (lowering perceived enablement benefits). (⑤) Beautiful-looking designs may not attract attention over time because people become desensitized to them.

* visceral: 본능적인 ** elicit: 이끌어 내다

Q1. 위치를 결정하는 데 근거가 된 단어나 표현에 밑줄을 그으세요. (5개)

※ 특정 순서가 적절하다고 판단한 근거, 또는 부적절하다고 배제한 근거 모두 포함하여 선택해 주세요.

Q2. Q1에서 밑줄 친 것 중 가장 결정적이었던 단어나 표현 하나에 동그라미 표시를 해 주세요. (반드시 하나)

실제 분석 단위는 Q1의 밑줄 5개이며,
Q2는 응답의 질 향상을 위한 장치.

응답자는 밑줄을 치는 동시에 '이 중 하나를 골라야 한다'는 것을 인지하기 때문에, Q1 단계에서부터 더 신중하게 근거에 집중하게 됨

Human test

LLM 과 비교했을 때보다는 attention 과 gradient가 비교적 균일!
하지만 아직 gradient가 약간 더 높음.

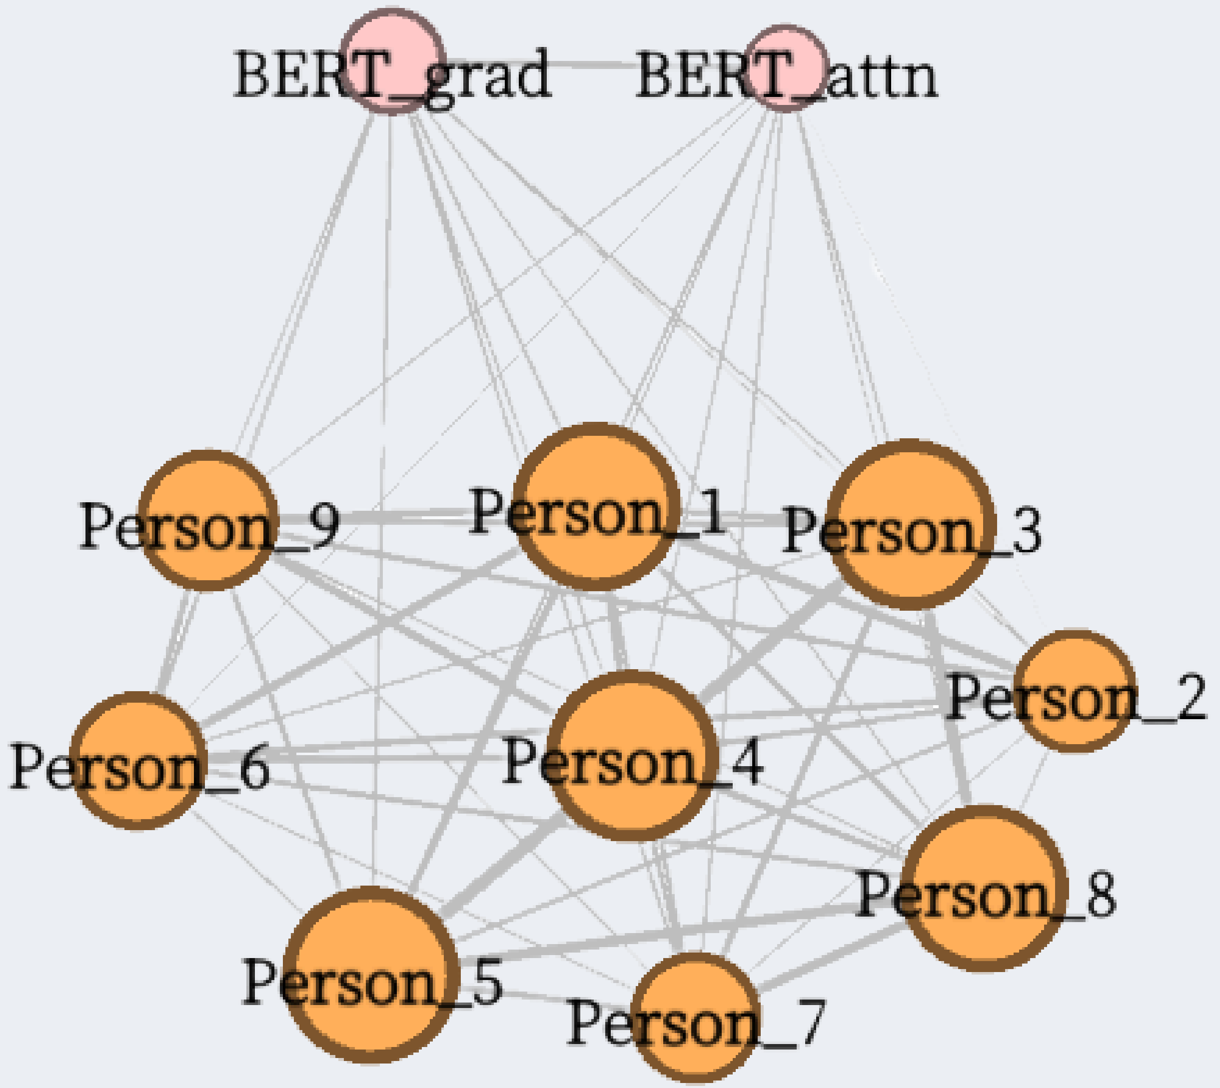

문장삽입

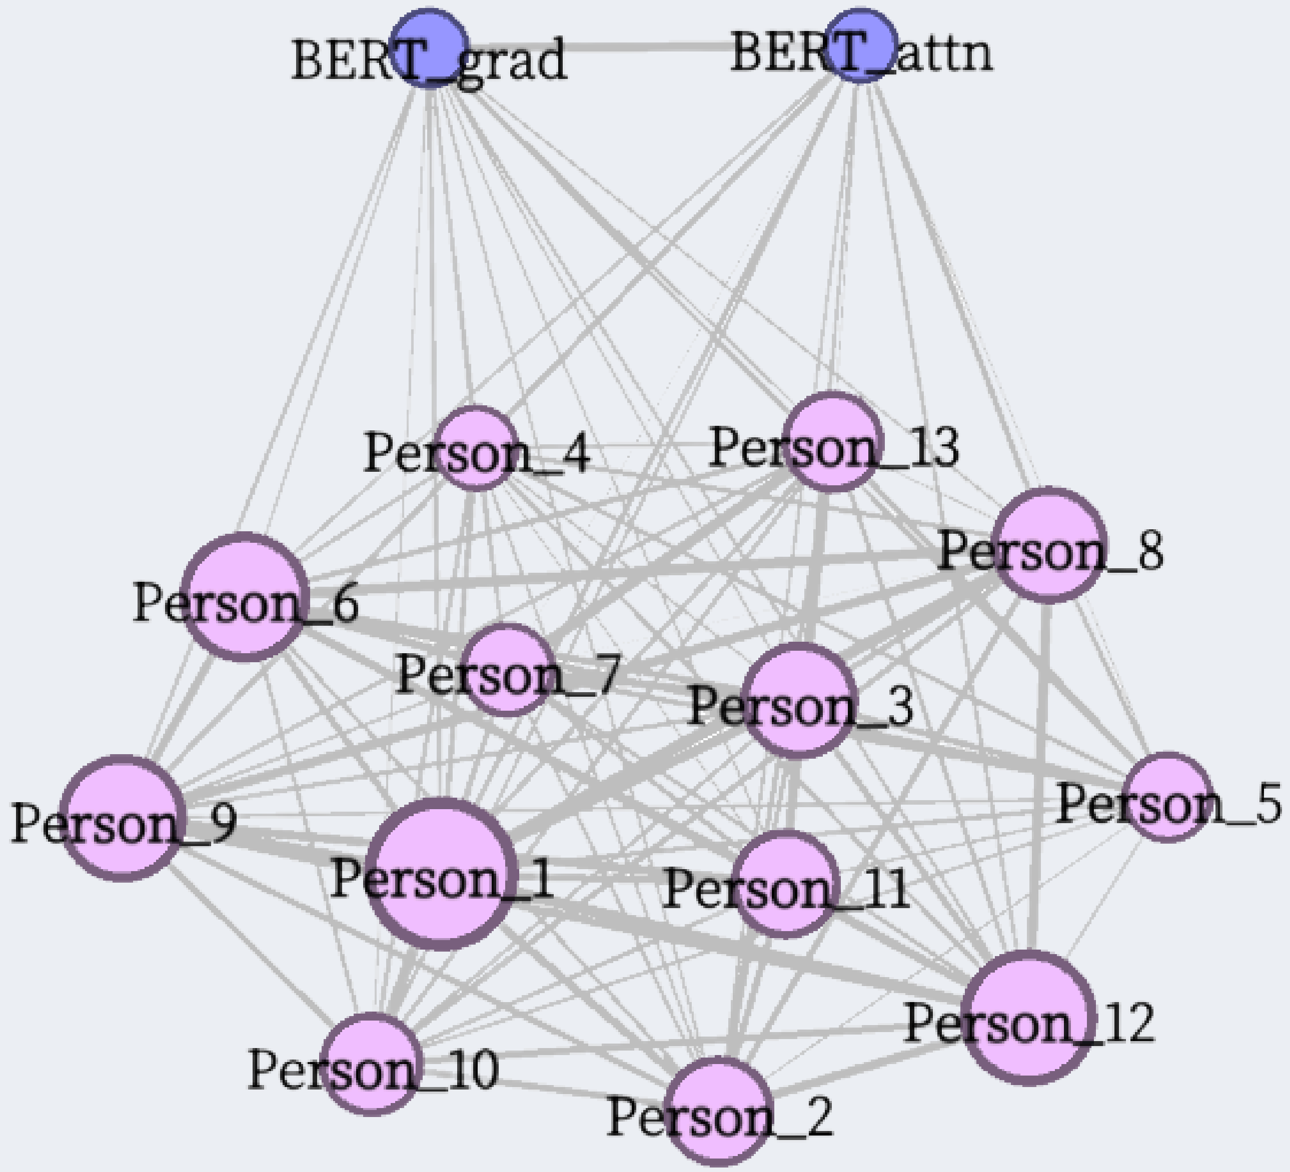

순서배열

결과

Sentence Ordering 에서 Attention layer 보다 Gradient 가
더 유용한 근거를 설명해 준다.

따라서 Attention 은 모델 내부의 주목한 단어를 상징할 수 있으나,
그대로 explainable한 근거가 될 수 없다.

따라서 explanable 은 gradient!!
모델 성능을 더 끌어올린 다음, 수능 영어 AI를 만들어 보자

DeBERTa-v3-base

What is DeBERTa?

Pretrained Language Model based on Transformer

Disentangled attention

Separates content and position

DeBERTa-v3-base

Uses RTD (Replaced Token Detection)

Distinguishes real vs replaced tokens

More efficient than MLM (Masked Language Modeling)

실험 2

Goal - Multiple Choice Ranking

- 여러 후보 위치 중에서 target 문장이 들어갈 가장 적합한 위치를 선택
- 각 후보 위치 i에 대해 score s_i 계산 후 상대적 비교

$$y = \arg\max_i s_i$$

Cross Entropy Loss

- score를 softmax를 통해 확률 P(i)로 변환
- 정답 위치에 해당하는 확률 P(y)가 최대가 되도록 cross entropy loss를 사용해 학습

$$P(i) = \frac{e^{s_i}}{\sum_j e^{s_j}}$$

$$L = -\log \frac{\exp(s_y)}{\sum_{i=1}^{C} \exp(s_i)}$$

DeBERTa-v3-base + Ranking Head

$$[LEFT]context \oplus [TARGET]target \oplus [RIGHT]context$$

DeBERTa Encoder

$$token_1 \rightarrow vector_1$$
$$token_2 \rightarrow vector_2$$
$$\cdots \qquad \cdots$$
$$token_n \rightarrow vector_n$$

Representation Extraction

$$h_{cls} \; h_{target} \rightarrow [h_{cls}; h_{target}]$$

final representation h

Scoring Network

$$h_i \rightarrow \boldsymbol{s_i}$$

$$candidate\ scores : s_1, s_2, \ldots, s_C$$

Ranking Module

Softmax over candidate scores

$$P(i) = \frac{\exp(s_i)}{\sum_j \exp(s_j)}$$

$$\hat{y} = \arg\max_i s_i$$

Output : selected insertion position

DeBERTa-v3-base + Ranking Head

Train Data	Test Pairwise Acc
arXiv papers abstract (100,000)	91.47%
CSAT	80.74%

DeBERTa-v3-base + Ranking Head

PMR(%)	Q38 [2점]	Q39 [3점]
93.2% (111/119)	95.0% (57/60)	91.5% (54/59)

SOM based on RoBERTa and Fusion

What is RoBERTa?

Pretrained Language Model based on Transformer

Contextual Representation

Self-Attention

Pretraining

What is Fusion?

In Context...
Fusion of

Semantic Information

Discourse Relation

Structural Information

SOM based on RoBERTa and Fusion

- Goal

두 문단 A, B의 상대적 순서를 예측

$$P(A \rightarrow B) = \sigma(score(A, B))$$

$$score(A, B) = FusionTransformer(RoBERTa(A \oplus B))$$

- Loss function

$$L_{BCE} = -\Sigma[ylogP(A \rightarrow B) + (1 - y)log(1 - P(A \rightarrow B))]$$

$$L_{rank} = max(0, margin - (score(A, B) - score(B, A)))$$

$$L = L_{BCE} + \lambda \cdot L_{rank}$$

SOM based on RoBERTa and Fusion

$$paragraph_A \oplus paragraph_B$$

$$\downarrow$$

RoBERTa Encoder

$$token_1 \rightarrow vector_1$$
$$token_2 \rightarrow vector_2$$
$$\cdots \qquad \cdots$$
$$token_n \rightarrow vector_n$$

$$\downarrow$$

Span Pooling

$$paragraph_A \rightarrow vector_1$$
$$paragraph_B \rightarrow vector_2$$

[2 x 1024]

$$\downarrow$$

SOM based on RoBERTa and Fusion

Discourse-aware FusionTransformer

Relative Node
+
Relative Position Encoding
+
Transformer-XL Attention

→ Fused node representations

↓

Fusion Nodes → Doc Pooler → FC → Classifier

→ Coherence Score(scalar)

↓

Output: 0~1 score

How to Parsing?

(1) 명시적 연결어 체크
(e.g. However, Therefore...)

(2) 암시적 연결관계 체크
based on
facebook/bart-large-mnli

label: Expansion, Contingency, Comparision, Temporal

SOM based on RoBERTa and Fusion

RoBERTa(24 Layers)

0 1 2 ... 19

20 21 22 23

+ Pooler
+ FusionTransformer

Component	Learning Rate
RoBERTa	1e-6
Fusion Head	1e-5

SOM based on RoBERTa and Fusion

Train Data	Test Pairwise Acc
arXiv papers abstract (100,000)	88.51%
CSAT	78.87%

SOM based on RoBERTa and Fusion

PMR(%)	Q36 [2점]	Q37 [3점]
84.5% (98/116)	87.9% (51/58)	81.0% (47/58)

Logic Bridge 웹페이지 시연